



Universidad Politécnica
de Madrid

**Escuela Técnica Superior de
Ingenieros Informáticos**



Grado en Ingeniería Informática

Trabajo Fin de Grado

**Aplicación de Reconocimiento de
Imágenes para Monitorización No
Intrusiva de Carga Eléctrica**

Autor: Hernán Calvo Aguiar
Tutor(a): Esteban García Cuesta

Madrid, Junio 2024

Este Trabajo Fin de Grado se ha depositado en la ETSI Informáticos de la Universidad Politécnica de Madrid para su defensa.

Trabajo Fin de Grado
Grado en Ingeniería Informática

Título: Aplicación de Reconocimiento de Imágenes para Monitorización
No Intrusiva de Carga Eléctrica

Junio 2024

Autor: Hernán Calvo Aguiar

Tutor: Esteban García Cuesta

Departamento de Inteligencia Artificial (DIA)

Escuela Técnica Superior de Ingenieros Informáticos

Universidad Politécnica de Madrid

Resumen

Aquí va el resumen del trabajo. Extensión máxima 2 páginas.

La Monitorización No Intrusiva de Carga, es una técnica que busca administrar los consumos de diferentes dispositivos eléctricos sin la necesidad de medir directamente cada uno de ellos.

El objetivo de este proyecto es desarrollar la pieza clave de este sistema. Una Inteligencia Artificial que permita identificar los dispositivos conectados y consumiendo a una red eléctrica, como podría ser una casa, un restaurante o una oficina.

El modelo a diseñar deberá ser capaz de identificar los dispositivos conectados a la red eléctrica, y estimar el tiempo de uso de cada uno. Para ello, se ha decidido hacer uso de CSPNet, un modelo potente, computacionalmente barato de entrenar

Este trabajo

Abstract

Abstract of the Final Degree Project. Maximum length: 2 pages.

Tabla de contenidos

1. Introducción	1
1.1. Motivación y Aplicaciones	1
1.2. Objetivos	2
1.3. Alcance del proyecto	2
1.4. Estructura de la Memoria	3
2. Fundamentos y Estado del Arte	5
2.1. Conceptos generales	5
2.2. Aprendizaje Automático	7
2.3. Redes Neuronales	8
2.3.1. Sparse Coding	8
2.3.2. Clasificadores de imágenes	9
2.3.3. Redes Recurrentes	9
2.4. SOTA	9
2.4.1. Codificación GAF	9
2.4.2. CSPNet	9
2.4.3. Validación de Modelos: NILMTK	10
3. Desarrollo	11
3.1. Planificación	12
3.2. REFIT Dataset	12
3.2.1. Características principales	12
3.2.2. Pros y contras del dataset	13
3.3. Parseado de REFIT a MYSQL	14
3.3.1. Inconvenientes	14
3.3.2. Modelo de la BBDD	14
3.3.3. Herramientas desarrolladas	15
3.4. Codificación GAF	16
3.4.1. Primer Diseño	16
3.4.2. Inconvenientes	18
3.4.3. Diseño Final	18
3.5. Modelo y Entrenamiento	18
3.5.1. Modelo	18
3.5.2. Pytorch	19
3.5.3. Entrenamiento	20
3.5.4. Inconvenientes	20

TABLA DE CONTENIDOS

4. Resultados y Análisis de Impacto	21
4.1. Resultados	21
4.2. Impacto	21
4.2.1. Personal	21
4.2.2. Empresarial	21
4.2.3. Económico	21
4.2.4. Medioambiental	21
5. Conclusiones y trabajo futuro	23
5.1. Conclusiones	23
5.2. Trabajo a Futuro	23
5.3. Alegato Final	23
Bibliografía	25
Anexos	31
A. Glosario	31
B. Repositorios	33
B.1. Código Fuente	33
B.2. Repositorios externos	33

Capítulo 1

Introducción

1.1. Motivación y Aplicaciones

Las técnicas de Monitorización No Intrusiva de Carga (en inglés NILM o Non Intrusive Load Monitoring) extraen el consumo de electrodomésticos a partir de una curva de consumo agregada. [1, pág. 1]. Dicho de otra forma. El monitoreo de carga no intrusivo es un sistema que infiere los consumos de diferentes dispositivos sobre una curva de consumo en la toma de corriente principal. Por ejemplo en la toma de corriente de una casa.

En Europa, un tercio de la energía eléctrica se ha generado mediante energías no renovables(12 % o 333TWh carbón, 17 % o 569TWh gas natural)[2] [3]. Aún siendo un descenso récord, para poder continuar reduciendo el consumo de energías no renovables, debemos desarrollar herramientas que nos permitan hacer un uso más inteligente de la generación de energía. Herramientas como la monitorización de carga no intrusiva pueden ayudarnos a detectar patrones de uso[4, pág. 11], para entonces poder desarrollar políticas que permitan optimizar la generación de energía.

Si, hipotéticamente, se redujese un 2 % la generación de electricidad a través de la combustión de carbón. Supondría una reducción de emisiones de 96.6 Millones de Toneladas de CO₂¹.

Realizar un monitoreo de carga no intrusivo es un problema complejo. Actualmente el área de soluciones NILM se encuentra en la fase de investigación y desarrollo. Por lo tanto. Mi objetivo para este trabajo es entrenar y analizar el rendimiento de una inteligencia artificial especializada en la clasificación de imágenes, transformando los datos de entrenamiento de series temporales a imágenes. Detallado en el **Capítulo 3**. El trabajo se centrará en cómo modificar el enfoque al problema de disgregación de consumos afecta al rendimiento de la técnica en comparación con otras técnicas del estado del arte.

Este concepto fue inventado por George W. Hart, Ed Kern y Fred Schweppe en

¹ $333 * 10^3 \text{GWh} * 290 \frac{\text{tCO}_2}{\text{GWh}}$ [5]

Capítulo 1. Introducción

el Instituto Tecnológico de Massachussets, en los años ochenta [6]. Fundados por el Electric Power Research Institute, podemos encontrar el proceso básico descrito en la patente estadounidense 4,858,141.

Una breve bibliografía de George W. Hart: Actualmente ejerce como escultor desde 2017. Tiene esculturas en exposición en Berkeley, Princeton, Cambridge, Duke, Brown... Cofundó el único Museo de las Matemáticas en Norteamérica y se ha retirado recientemente, trabajó en ciencia computacional, matemáticas, educación e investigación [7].

La técnica, descrita por Hart, Kern y Schweppe en [6] modela los consumos en lo que nombran como «Modelo Total de Carga». El modelo total de carga depende de que dispositivos estén encendidos en un momento dado. Por lo que definen un 'proceso de cambio'. Esto nos lleva a un problema computacionalmente imposible de resolver salvo mediante la fuerza bruta[6, pág. 4] y poco margen de mejora en el modelado para simplificar su resolución. De manera resumida, el problema trata en encontrar el número de dispositivos y el consumo de cada uno. Este es un problema que se beneficia de hacer uso de modelos heurísticos.

Siguiendo este objetivo y con el asesoramiento de Esteban García Cuesta, se decidió en hacer uso de datasets clasificados para un entrenamiento supervisado; además de una arquitectura potente, compacta y computacionalmente baja en costes de entrenamiento.

extender motivación y aplicaciones, citar más motivaciones

1.2. Objetivos

Previamente al comienzo del desarrollo del proyecto, se establecieron una serie de objetivos a cumplir, dividiendo el objetivo final en pasos coherentes y concretos. En esta sección se detallan los objetivos de aprendizaje e investigación:

Este trabajo busca investigar sobre las técnicas más actuales en NILM². Dando al lector una base de las técnicas utilizadas en el estado del arte y las matemáticas detrás de estas técnicas. Los objetivos de aprendizaje son extensos, el trabajo busca además profundizar en la práctica detrás de el entrenamiento de una inteligencia artificial y de los retos que presenta el uso de la computación paralela, bases de datos, GPUs, lenguajes de bajo nivel (C++, OpenCL) y el uso de frameworks de creación, entrenamiento y análisis del rendimiento de la inteligencia artificial.

1.3. Alcance del proyecto

Al finalizar este proyecto, se busca tener un modelo capaz de realizar una monitorización de carga no intrusiva, además de una serie de progamas y herramientas útiles a la hora de realizar trabajos futuros en el área.

²ver Apéndice A para un glosario de términos

1.4. Estructura de la Memoria

La memoria de esta investigación tiene los siguientes capítulos.

- **Introducción:** Se introduce el tema, sus potenciales aplicaciones, motivación, alcance...
- **Fundamentos y Panorama Actual:** Este capítulo sirve para dar al lector una base de la teoría detrás de la tecnología, algoritmos y conceptos sobre los que se desarrolla el trabajo de fin de grado. Además de informar sobre el estado del arte en el área.
- **Desarrollo:** En este capítulo se detallan los pasos tomados para el desarrollo del modelo y las herramientas que utiliza. Entrenamiento, codificación, evaluación del modelo, etc.
- **Resultados y Análisis de Impacto:** Este apartado recoge los resultados del modelo y se compara su rendimiento con otros modelos. Además recoge el análisis del impacto del modelo conforme a los Objetivos de Desarrollo Sostenible de la Agenda 2030.
- **Conclusiones y Trabajo Futuro:** En este capítulo se recogen las conclusiones del trabajo y el trabajo futuro que puede hacerse para mejorar el modelo y sus partes.
- **Bibliografía:** Se recogen todos los recursos bibliográficos citados durante el transcurso de la investigación.
- **Anexo:** Detalla código e información de interés que no tiene cabida en el cuerpo del texto.

Capítulo 2

Fundamentos y Estado del Arte

Capítulo dedicado a describir los fundamentos y el panorama actual del trabajo.

2.1. Conceptos generales

El concepto de NILM desde su introducción ha sido el método preferido por ingenieros e investigadores para la disgregación de consumo eléctrico desde su introducción, debido a sus ventajas económicas y prácticas.[8, pág. 2, pár. 4]

En cuanto al origen de este método, se buscó categorizar en [6] los dispositivos dentro de tres grandes grupos, para poder estructurar los diferentes dispositivos y generalizar el modelado de dispositivos específicos. Estos grupos son:

1. **Señales de estados fijos** Siguen la arquitectura de una máquina de estados finita, las transiciones entre estados son consumos exactos, al igual que los estados
2. **Señales transitorias** Esto son señales que no se encuentran en un espacio discreto que permita modelar su comportamiento como una máquina de estados. Un ejemplo podría ser un calefactor automático, que regula su generación de calor en función de la diferencia de la temperatura ambiente y la temperatura objetivo.
3. **Otras** Señales que no pueden categorizarse en ninguno de los dos casos anteriores. Por ejemplo, los cambios de dirección del motor de una lavadora en el proceso de lavado.

Cabe mencionar que los propios investigadores reconocieron que en el futuro los dispositivos eléctricos que siguiesen un diseño de máquinas de estados perderían precedencia. Ya que habría más 'dispositivos inteligentes' [6]. Actualmente, una calefacción programable o un aire acondicionado programable están al alcance de cualquiera. En 2021, en España el 50 % de las viviendas en alquiler constan de aire acondicionado[9].

Y esto es sólo un dispositivo. Habrá cientos de modelos de cada dispositivo, decenas de marcas, cada dispositivo con sus características específicas. Un mo-

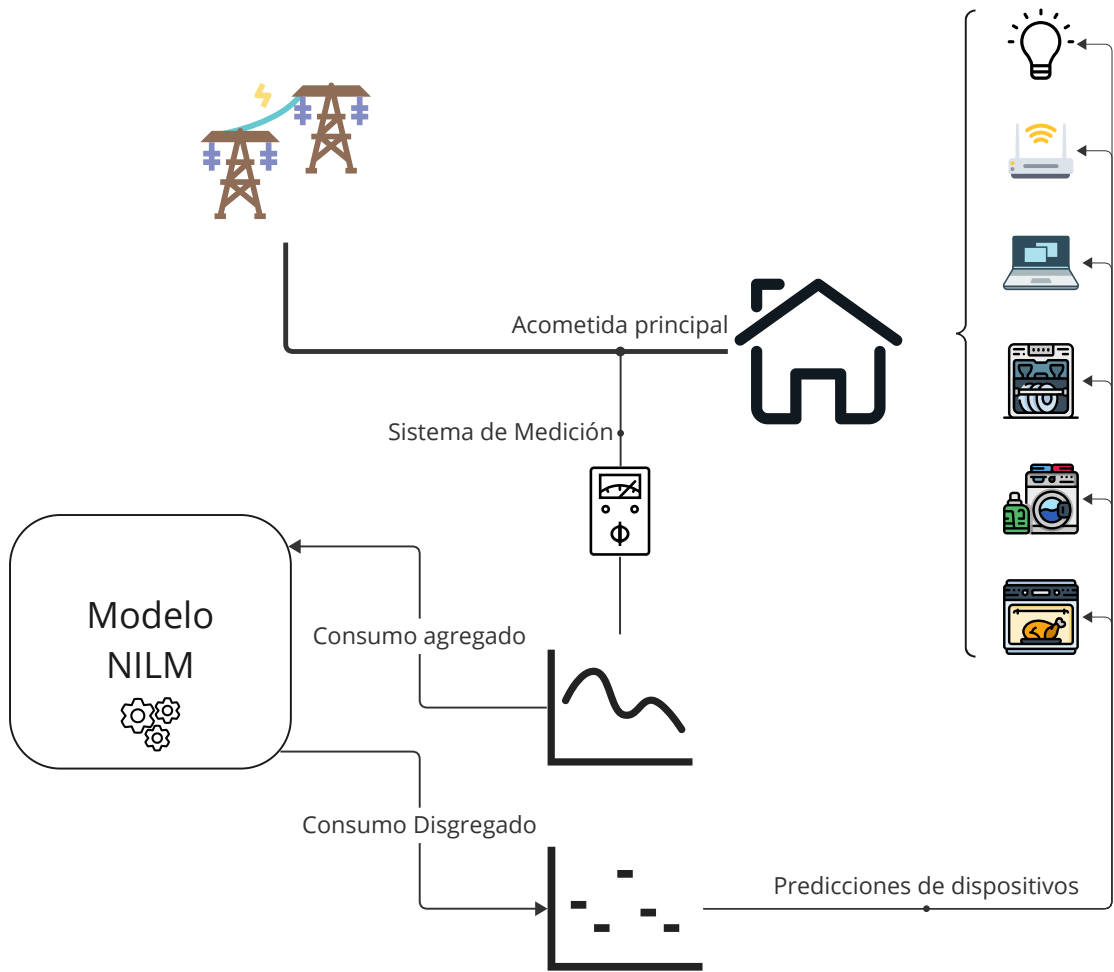


Figura 2.1: Un diagrama simple de un sistema NILM

delado exhaustivo sería prácticamente imposible de crear y mantener, ya que sólo para el mercado doméstico hay una cantidad desorbitante de dispositivos, combinaciones de dispositivos, etc.

Un ejemplo de sistema NILM

Un sistema NILM consta de las siguientes partes: Una fuente de datos (acometida principal). Un dispositivo de recogida de datos (puede ser de Potencia Activa Y reactiva, Voltaje e Intensidad, etc). El modelo predictivo. Y el sistema de consulta de datos, que se ha omitido en la Figura 2.1.

Debido a estos argumentos, la investigación de la monitorización no intrusiva se inclinó a los modelos heurísticos y el aprendizaje automático.

repasar motivos para el transfer learning

2.2. Aprendizaje Automático

En la Historia de la Inteligencia Artificial, se han definido una serie de etapas de gran crecimiento y financiación como «veranos» (tres concretamente). Alternados por (dos) «inviernos»; donde el interés, la financiación y el número de publicaciones decrecían significativamente [10]. En los principios de la década de los 2010, comenzó el tercer «verano» de la Inteligencia Artificial. En 2012 ocurre un avance técnico: unos años antes, Olga Russakovsky creó el reto ImageNet [11]; un repositorio de más de un millón de imágenes de objetos a lo largo de más de mil categorías diferentes. Este reto estimuló a la comunidad científica,

Resulta lógico que el número de artículos científicos proponiendo modelos que permitiesen resolver los retos que presenta NIML aumentase.

De los que voy a destacar los Modelos Ocultos de Markov, el Sparse Coding y finalmente las Redes Neuronales. Siendo estas últimas el foco principal del trabajo, y de este capítulo.

Identificando Datos Ocultos Con Cadenas de Markov

Una cadena de Markov resulta útil cuando tenemos que modelar un comportamiento en base a una secuencia de eventos observables, siendo L.E. Baum y Ted Petrie los autores de [12], el primero de una serie de papers sobre modelos probabilísticos y estadística que introdujeron los HMM. Estos eventos observables son elementos conocidos, pero la secuencia de estados del modelo para esos eventos observables son desconocidos.

El problema, como en NILM, es que los estados no son directamente observables. Estan *ocultos* y por tanto debemos ajustar la cadena para incluir una secuencia de posibles similitudes observadas [13].

En el caso de una cadena de Markov. Dados una serie de eventos observables, podemos inferir la probabilidad de cada estado que causaron estos eventos observables: Calculando la probabilidad de una cadena de eventos observables dada la probabilidad de una cadena de estados del conjunto, para todas las posibles combinaciones de la cadena los estados del conjunto. Este algoritmo se conoce algoritmo de Viterbi.

Este es el modelado que nos permite inferir de manera probabilística. Cabe añadir que las cadenas de markov tienen una serie de algoritmos para determinar la cadena de estados ocultos más probable para la cadena de eventos observables, se omite por brevedad, pero puede consultarse [13] para una excelente y detallada explicación sobre este área.

Modelos Ocultos de Markov

Explicadas brevemente las bases de los Modelos Ocultos de Markov, pasamos a la aplicación de este modelo estadístico en la disgregación de consumos.

Dado que un modelo de markov oculto infiere probabilísticamente una serie de estados, esto nos resulta útil para la disgregación de dispositivos. Para codificar diferentes estados de diferentes dispositivos se aumenta el número de cadenas del modelo. Teniendo una matriz de estados S_i^j donde S es un conjunto de estados; las observaciones dependen de todos los estados en un momento dado. Podemos observar esto en el siguiente diagrama:

Los Modelos de Markov Ocultos se han tratado en la literatura como efectivos en comparación con otras técnicas de monitorización cuando el entrenamiento supervisado presenta una baja tasa de muestreo en el eje temporal de la obtención de datos [14]. Otras ventajas que presenta es su bajo coste computacional en el entrenamiento. Pero el uso de este tipo de elementos lo vuelven altamente susceptible a máximos locales[1].

En el caso de los Modelos Factoriales de Markov Ocultos (con siglas FHMM en inglés), presentan ciertas ventajas en comparación con los HMM¹: La complejidad y el coste computacional de los algoritmos de aprendizaje e inferencia son menores para los HMM. Sin embargo, tanto FHMM como HMM presentan limitaciones al volumen máximo de dispositivos simultáneos, incluso en casos como [15] donde se propone un nuevo algoritmo no supervisado. El algoritmo desarrollado (AFMAP) no presenta los problemas de alta complejidad y máximos locales, pero requiere de etiquetación manual después de la disgregación. Y presenta bajo rendimiento para dispositivos electrónicos y de cocina [1, pág. 5].

2.3. Redes Neuronales

En esta sección se tratan tres conceptos de las Redes Neuronales; se dará una introducción y se expondrán las aplicaciones pertinentes al tema del proyecto. Por motivos de brevedad, se asume que el lector tiene una cierta base en inteligencia artificial. En caso contrario, sugiero consultar las citas y el Apéndice A

2.3.1. Sparse Coding

Introducido por Olshausen et al., 1997 [16]. El Sparse Coding consiste en reducir la activación de la capa oculta de las neuronas, forzando a la red neuronal a realizar un aprendizaje [17]. Su objetivo es encontrar un conjunto de vectores ϕ_i tal que podamos representar un vector x como una combinación lineal de estos vectores:

$$x = \sum_{i=1}^k a_i \phi_i$$

Este es un concepto que está fuertemente relacionado con los autoencoders y el aprendizaje PCA.

¹Hidden Markov Models, o en español los Modelos Ocultos de Markov

Que tienen como objetivo es que su salida sea igual a la entrada, pero limitando la capa oculta para forzar un aprendizaje [18]. Por ejemplo, supongamos que buscásemos utilizar un autoencoder para comprimir una imagen para enviarla por internet. Si no implementásemos restricciones, dado que el objetivo de la red neuronal es reducir la pérdida de información a 0; la salida del autoencoder sería la imagen, completamente idéntica.

Para evitar esto en el caso de los autoencoders se introduce una capa oculta de menor tamaño en comparación a la capa de entrada como restricción para forzar un aprendizaje, al tener una capa oculta, la capa de salida (de igual tamaño a la de entrada) debe «reconstruir» la entrada [18] .

Volviendo al Sparse Coding. Al tener un conjunto de vectores sobrecompleto, los coeficientes a_i ya no se determinan únicamente por el vector de entrada x . Luego se define una función de escasez². Definimos esta función de escasez como: tener los menos componentes (a_i) distintos de cero o el mínimo de componentes no cerca de cero [17].

Tanto los autoencoders como el sparse coding han sido usados en la literatura NILM. sparse coding:[19]

Pendiente continuar investigando

2.3.2. Clasificadores de imágenes

hablar de proyectos que usen clasificadores

hablar de proyectos que usen resnext

2.3.3. Redes Recurrentes

hablar de proyectos que hagan uso de redes recurrentes

2.4. SOTA

2.4.1. Codificación GAF

La codificación elegida está motivada por

cita pendiente

2.4.2. CSPNet

entrar en detalle sobre CSPNet, sus creadores y proyectos SOTA que hagan uso de CSPNet

²De ahí el «Sparse»; escasez en Español

2.4.3. Validación de Modelos: NILMTK

hablar potencial implementación a futuro en nilmtk y papers que citan nilmtk

Capítulo 3

Desarrollo

El hardware utilizado tiene las siguientes especificaciones:

- CPU: AMD Ryzen 5 3600XT (12) @ 3.800
- GPU: AMD Radeon RX6800XT
- RAM: 16GB CL16 @ 3000
- DISCO: SSD NVME 500GB
- SSOO: Linux 5.15.0-107-generic #117 20.04.1-Ubuntu

El desarrollo fue realizado en Visual Studio Code, haciendo uso de Git y GitHub como sistema de control de versiones y copia de seguridad remota del desarrollo realizado. El repositorio consta de la siguiente estructura de carpetas:

```
datasets/  
  CLEAN_REFIT_081116/  
encoding  
  REFIT_GAF/  
    house1/  
    ...  
    house21/  
    meta/  
  thSafe/  
full_model  
  cspvenv/  
  data/  
    REFIT_GAF -> /encoding/REFIT_GAF  
  first_test/  
  src/
```

3.1. Planificación

Se realizó dos tandas de organización y planificación de tareas. La primera al principio del semestre y la segunda a mediados de abril. Las dificultades en la planificación fueron una combinación de motivos externos y una perspectiva algo ingenua del tiempo a invertir y el ritmo de progreso. Debido a la falta de conocimientos, se ha dedicado un tiempo considerable (unas 60-80 horas) a realizar investigación y estudio, para poder comprender las técnicas y modelos implementados el estado del arte.

En lo que respecta al desarrollo, se han dedicado unas 80-100 horas.

Los principales problemas fueron: la dificultad para programar un codificador en C++ y OpenCL, debido a la curva de dificultad que representa aprender un lenguaje para una nueva arquitectura y los retos que presenta la gran cantidad de datos usada para el entrenamiento de inteligencia artificial.

3.2. REFIT Dataset

Tras una investigación de los potenciales datasets, se decidió usar como dataset REFIT. El nombre completo del dataset es «Personalised Retrofit Decision Support Tools For UK Homes Using Smart Home Technology»[20].

3.2.1. Características principales

Puede encontrarse todo el detalle sobre el dataset en [20].

El dataset recoge datos de 20 casas durante un periodo continuo de dos años, con un periodo de medición superior a un minuto entre mediciones para todas las casas. Siendo este el único dataset de Gran Bretaña con estas características. Se miden 9 dispositivos además del consumo agregado. Todas las mediciones se realizaron en vatios.




Figura 3.1: El modelo de recolección de datos (propiedad de [20])

El dataset ocupa unos 5GB de memoria, se presentan todas las mediciones de una sola casa en archivos CSV. Siguiendo la distribución:

Time, Unix, Aggregate, Appliance1, ... , Appliance9, Issues

Habiendo 21 archivos en total que recogen datos, y un vigésimo segundo archivo conteniendo los metadatos de cada casa. Estos metadatos se limitan a especificar el tipo de dispositivo asociado al dispositivo o *Appliance*

añadir unas líneas de una casa y una y sus metadatos

En cuanto a la recogida de datos, se definió un periodo de recogida de datos de ocho segundos. Por tanto los datos se recogieron con un desplazamiento temporal. Esto quiere decir que los datos de los dispositivos y el agregado no coinciden exactamente en el tiempo, habiendo una diferencia de unos segundos entre dispositivo y dispositivo. El acumulado (o agregado) se calculaba antes de que finalizase el periodo de ocho segundos.

3.2.2. Pros y contras del dataset

Las ventajas de este dataset son, su longitud en el tiempo y la facilidad de empezar a hacer un uso de los mismos. Ya que se busca investigar sobre la viabilidad de un modelo que haga uso de clasificadores de imágenes, esto habilita la posibilidad de realizar un trabajo de fin de grado con este tema.

Hay una serie de problemas conocidos sobre el dataset. En la publicación asociada se mencionan los siguientes:

Capítulo 3. Desarrollo

- Ocasionalmente los medidores de dispositivos reportaban consumos muy por encima de la carga máxima para un dispositivo de uso doméstico. Estas medidas se eliminaron del dataset.
- Hubo problemas con la sincronización temporal de los medidores de dispositivos. Esto conlleva discrepancias entre el agregado y las mediciones.
- Las mediciones del acumulado en casas 3, 11 y 21 se vieron afectadas debido a que los domicilios contaban con paneles solares, y recablear para evitar afectar a las medidas del acumulado no era posible.
- En algunos casos, los valores entre acumulado y dispositivos no coinciden debido a que no se monitorizaron otras variables para ajustar estas medidas conforme el ángulo de fase o el voltaje por cargas inductivas o capacitivas.

Debido a falta de clasificación en los metadatos, las casas 12 y 13 no fueron utilizadas para el entrenamiento.

3.3. Parseado de REFIT a MYSQL

Como primer paso, se decidió parsear todos los datos a una BBDD, escogiendo MYSQL como plataforma, para tener una lógica de acceso que permitiese ordenar los datos para su codificación conforme a diferentes algoritmos (secuencial, k-means) para poder extraer la mayor cantidad de características sobre los dispositivos en diferentes marcos temporales.

3.3.1. Inconvenientes

La inserción de datos en la base de datos fue tremendamente lenta. Para insertar un CSV entero, se tardaba en el peor de los casos cerca de las 72h de inserción continuada. En parte esto se debe a que se mantuvo durante un tiempo la configuración del servidor MYSQL *out of the box* sin realizar ningún cambio.

Más adelante se investigó cómo poder optimizar las inserciones. La solución fue reducir el número de inserciones a la base de datos y aumentar el volumen de datos por inserción. Quinientas mediciones por INSERT redujeron drásticamente el tiempo necesario, de 3 días a unos 15 minutos.

3.3.2. Modelo de la BBDD

Para este paso del desarrollo, se decidió un modelo simple, imitando la presentación de los datos en el csv.




Figura 3.2: El modelo de la BBDD en el parseo

3.3.3. Herramientas desarrolladas

Para la inserción, se diseñaron dos programas en C++. Haciendo uso de la librería de conector de C++ a mysql. Se seleccionaba el archivo manualmente y comenzaba la inserción. Una vez iniciada la inserción de datos, esta se paraba en la misma fecha, el 31 de marzo. Esto se debía a que al insertar la fecha, habiendo un cambio de hora esa madrugada, las fechas no coincidían con las esperadas.

La solución a este problema fue desarrollar un programa que permitiese saltar a la línea donde daba el fallo, además de una serie de herramientas para «debuggear» la inserción de datos, pudiendo saltar a una línea específica e insertar manualmente o continuar la inserción.

Podemos observar el comportamiento de la herramienta, llamada sin argumentos:

```
$ ./traversecsv
Usage: ./traversecsv <file> <house_id>
```

Y llamada con argumentos

```
$ ./traversecsv CLEAN_REFIT_081116/CLEAN_House15.csv 15
Successfully connected to the database!
Total lines in file: 6225697
Press 'p' to print the next line
'i' to continue inserting
```

Capítulo 3. Desarrollo

```
'j' to jump to a specific line
'r' to continue inserting until EOF
's' to search for a line with a specific date
```

Además de desarrollar el programa, se cambió la configuración de fechas en el servidor MYSQL.

```
SELECT @@global.time_zone, @@session.time_zone;
SET GLOBAL time_zone = '+00:00';
SET SESSION time_zone = '+00:00';
```

Este programa y su código fuente puede encontrarse a partir de la raíz del directorio dentro de «*datasets/*».

incluir datos del rendimiento del programa en el sistema

3.4. Codificación GAF

El método de codificación sigue una serie de pasos relativamente simples:

```
(pseudocódigo)
1. Dado un vector  $V$  de  $n$  elementos.
for ( $n$ )
     $V(n) = \arccos(V(n))$ 
    if  $V(n) > 1$ 
         $V(n) = 1$ 
    else if  $V(n) < -1$ 
         $V(n) = -1$ 
2. construimos la matriz  $M$ 
for ( $i$ )
    for ( $j$ )
         $M = \cos(V(i) + V(j))$ 
```

3.4.1. Primer Diseño

Dado el volumen de los datos, se ideó un programa multihilo, con gestión asíncrona de llamadas y computación en GPU via kernels de OpenCL.

Se decidió separar el proceso de codificación en tres partes. Extracción de datos, Codificación de datos y Almacenamiento de Metadatos.

La extracción es altamente paralelizable. Consiste en extraer de la base de datos en bloques de un cierto tamaño y preparar series de datos para guardarlos en una estructura de datos accesible para los hilos posteriores. Se decidió por un hashmap thread safe. Para notificar a los procesos de codificación qué series están listas, se introdujo una cola con mecanismos de sincronización para evitar posibles condiciones de carrera. Para reducir la redundancia de datos y el espacio de las estructuras de datos, sólo se introducen en la cola de series extraídas las claves resultantes de insertarlas en el hashmap.

Los hilos codificadores consumen claves de la cola de series extraídas, copiando las series del hashmap a un buffer y codificando el buffer. Se hace uso de un buffer por el mismo motivo que la extracción es en bloques de datos, para reducir el overhead de hacer una llamada de sistema. Una vez codificada una serie, se introduce de vuelta en el hashmap y se introduce su clave en la cola de series codificadas.

El Almacenamiento de metadatos copia el vector one-hot generado por el extractor y lo apenda a un archivo de texto. Las series codificadas siguen la misma convención para sus archivos.

La motivación de gestionar las llamadas asíncronas debido a que el conector a la BBDD MYSQL las soportaba pero no daba más alternativas que la espera activa llevó al desarrollo de la clase *EventLoop.hpp*. Se tomó prestado un concepto muy usado en servidores, en los que los sockets de un servidor (procesos individuales) traspasan sus peticiones a un proceso que se encarga de ejecutar las peticiones. Manteniendo así el coste de mantener una conexión con un servidor como un elemento separado de las operaciones del servicio. En el caso de la codificación, se implementó una solución de inserción de peticiones asíncronas, basado en promesas y futuros de funciones lambda que los procesos enviaban al EventLoop. Este se encargaba de recibirlas e instanciar un thread para ejecutar la petición, comprobando todas las peticiones de manera cíclica y devolviendo las promesas a los threads peticionantes (ver 3.3).

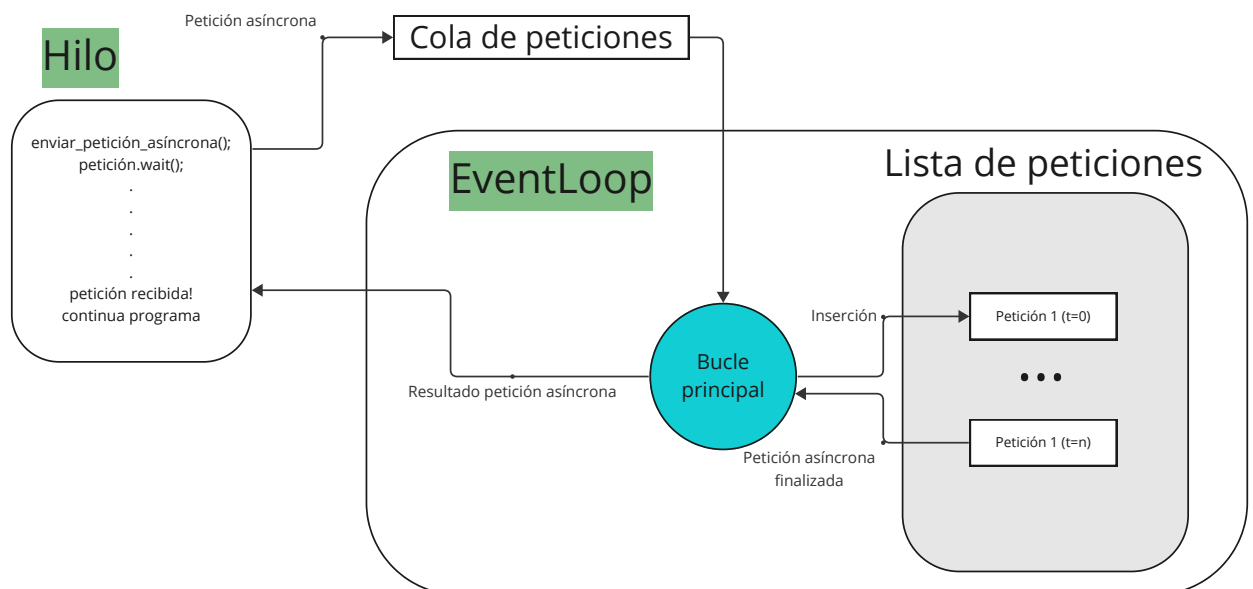


Figura 3.3: Diseño abstracto del funcionamiento del EventLoop

3.4.2. Inconvenientes

Este proceso de desarrollo se vio afectado por la optimización prematura. Sin embargo, se realizaron una serie de aprendizajes muy útiles en áreas que podrían beneficiar a futuro la escalabilidad de procesos como este en el campo de la inteligencia artificial.

EventLoop

Aún presentando una serie de ventajas a escala, la dificultad de devolver punteros sin desreferenciarlos fue el principal obstáculo de este sistema. Por lo que sólo se hizo un uso parcial de la solución desarrollada.

OpenCL

Para la codificación de datos se intentó realizar un desarrollo de kernels en OpenCL que aprovecharan las ventajas de computación paralela de la GPU. Debido a una falta de experiencia en desarrollo en OpenCL y a la naturaleza temporal del trabajo, se debió de abandonar esta rama.

3.4.3. Diseño Final

Debido a los inconvenientes expuestos, el diseño final se hizo exclusivamente en la gpu, haciendo uso de openCV para construir las imágenes.

Se decidió instanciar tríos de hilos.

análisis de rendimiento

Tiempo transcurrido en la codificación de los datos contenidos en *datasets/CLEAN_REFIT_081116/CLEAN_House21.csv*.

```
time ./host 22 7 21031 256
```

```
real    6m28,529s
user    38m35,273s
sys     1m52,445s
```

3.5. Modelo y Entrenamiento

3.5.1. Modelo

Se hace uso del modelo preentrenado CSPResNeXt50 de la librería timm por HuggingFace [21]. Debido a la naturaleza multidimensional de los datos y a las predicciones deseadas del modelo, se requiere una serie de ajustes a la capa de entrada y a la de salida. Por lo tanto los pesos de esas dos capas serán perdidas.

El modelo CSPResNeXt50 es un modelo de clasificación de imágenes. El objetivo de este trabajo es aplicar transfer learning a un modelo ya preentrenado, para

3.5. Modelo y Entrenamiento

estudiar el rendimiento del modelo en un problema de clasificación de series temporales codificadas como imágenes.

Este modelo se basa en la arquitectura ResNeXt50, cuyas principales ventajas radican en la eficiencia de la red y el uso de la cardinalidad (dimensión extra) para aprender características más complejas, aumentando la precisión sin aumentar el ancho o profundidad de la red [22]. La arquitectura CSPNet se basa en la arquitectura ResNet, pero con la adición de un módulo CSP (Cross Stage Partial) que permite la fusión de características de diferentes etapas de la red, permitiendo una mejor generalización y aprendizaje de características más complejas [23].

Se decidió por un modelo multitarea. Ya que lo que muchos modelos no han alcanzado a realizar de forma exitosa es una clasificación de dispositivos eléctricos y una estimación del tiempo en el que se encuentran encendidos.

Por tanto se establecieron dos salidas para el modelo. Una salida de clasificación de dispositivos eléctricos conforme al número de clases totales presentes en el dataset y una para estimar el tiempo en el que se encuentra cada uno de los dispositivos encendidos durante el elemento de entrenamiento suministrado. Estos datos son dos vectores de 23 elementos cada uno. El primero es un vector one-hot y el segundo es un vector de valores enteros que representan el número de instancias de cada clase en la imagen.

salida de regresión?

modelo de la red

3.5.2. Pytorch

Debido a que el único modelo que se encontró que cumplía los requisitos (modelo preentrenado, clasificación de imágenes, enfoque CSPNet) fue el modelo CS-PPResNeXt50, se decidió hacer uso de la librería Pytorch para el entrenamiento del modelo, ya que el modelo preentrenado se encontraba en la librería timm de HuggingFace. Los modelos con enfoque CSPNet están fuertemente relacionados con la clasificación de imágenes que hacen uso de capas especializadas para la extracción de características que no resultan ventajosas para la tarea en cuestión. Por lo que la mayoría de modelos requerían una serie de modificaciones que salían del alcance del proyecto.

Para entrenar el modelo se hizo uso de la librería Pytorch, que permite el uso de la GPU para el entrenamiento de modelos de aprendizaje profundo. Para esto, se instaló el módulo ROCm de Pytorch, que permite el uso de las GPU de AMD. Y la librería de Pytorch compatible con ROCm

El proceso de entrenamiento escogido fue el de desarrollar un script que implementa el dataloader de pytorch para cargar las imágenes codificadas y sus etiquetas. Y el desarrollo de un script que realiza las modificaciones necesarias al modelo para poder cumplir los requisitos de la tarea.

modelo de los datos de entrada y salida

3.5.3. Entrenamiento

Se desarrolló un script de entrenamiento. Los parámetros escogidos fueron los siguientes:

- Número de épocas: 31
- Tamaño del batch: 20
- Learning rate: 0.001
- Optimizador: Adam
- Función de pérdida 1: CrossEntropyLoss
- Función de pérdida 2: MSELoss

El entrenamiento se realizó en una GPU AMD Radeon RX6800XT. El tiempo de entrenamiento fue de en torno a las 12 horas para las 31 épocas.

En cuanto al cálculo de la pérdida, se decidieron por dos funciones de pérdida. La primera, CrossEntropyLoss, para la clasificación de los dispositivos eléctricos. La segunda, MSELoss, para de los tiempos en los que se encuentran encendidos los dispositivos eléctricos.

la regresión?

3.5.4. Inconvenientes

El entrenamiento del modelo se vio afectado por la falta de experiencia en el uso de Pytorch y la falta de tiempo para investigar y aprender sobre la librería. Sin embargo, se logró realizar un entrenamiento exitoso del modelo. Los principales inconvenientes que presenta el modelo se deben al tamaño de la red preentrenada. Es muy grande y podría beneficiarse de una reducción de tamaño. Además, el modelo CSPResNeXt50 no es el más ligero, por lo que el entrenamiento del modelo es lento y requiere de una GPU potente para poder realizarlo en un tiempo razonable. Debido al hardware disponible, la GPU requirió de una serie de ajustes (undervolt, limitación de potencia y regulación de relojes) que limitaron el número de épocas que podían realizarse en un tiempo razonable.

Capítulo 4

Resultados y Análisis de Impacto

4.1. Resultados

Resultados del modelo, comparación con otros modelos.

4.2. Impacto

4.2.1. Personal

Mayor control de gasto, menos privacidad. Análisis de patrones de gastos y por tanto hábitos personales/de la vivienda

4.2.2. Empresarial

industria: mayor control y más barato. (explicar pq) del gasto energético

4.2.3. Económico

mejora de la gestión energética lleva a mayor eficiencia, optimización y a mejor aprovechamiento de las energías renovables

4.2.4. Medioambiental

pro: aprovechar el consumo/optimizar los patrones de gasto teniendo mayor granularidad y un modelo inferente como el que se ha desarrollado permite construir en un futuro herramientas predictivas de gastos que por tanto pueden aportar info valiosa para modelos más generales (usando estos y otros datos como los meteorológicos, mercantiles, mercados, etc) para estimar la demanda esperada y el volumen de energía a generar.

Se recomienda analizar también el potencial impacto respecto a los Objetivos de Desarrollo Sostenible (ODS), de la Agenda 2030, que sean relevantes para el trabajo realizado (ver enlace)

Capítulo 5

Conclusiones y trabajo futuro

5.1. Conclusiones

5.2. Trabajo a Futuro

5.3. Alegato Final

Bibliografía

- [1] A. Faustine, N. H. Mvungi, S. F. Kaijage y M. Kisangiri, «A Survey on Non-Intrusive Load Monitoring Methodies and Techniques for Energy Disaggregation Problem», *CoRR*, vol. abs/1703.00785, 2017.
- [2] *Shedding light on energy in Europe - 2024 edition - Eurostat*. DOI: 10.2785/88627. dirección: <https://ec.europa.eu/eurostat/web/interactive-publications/energy-2024#about-publication>.
- [3] S. Brown y D. Jones. (2024). *European Electricity Review 2024*, Ember, dirección: <https://ember-climate.org/insights/research/european-electricity-review-2024/>.
- [4] J. Revuelta Herrero, Á. Lozano Murciego, A. Barriuso, D. Hernández de la Iglesia, G. Villarrubia, J. Corchado Rodríguez y R. Carreira, «Non Intrusive Load Monitoring (NILM): A State of the Art», jun. de 2018, págs. 125-138, ISBN: 978-3-319-61577-6. DOI: 10.1007/978-3-319-61578-3_12.
- [5] J. C. Romero Mora, *Anyone know a scientific reference about converting kwh electricity to CO2 emission?*, dic. de 2014. dirección: <https://www.researchgate.net/post/Anyone-know-a-scientific-reference-about-converting-kwh-electricity-to-CO2-emission#:~:text=In%202013%2C%20it%20was%200%2C29%C2%A0Kt%20CO2/GWh>.
- [6] G. Hart, «Nonintrusive appliance load monitoring», *Proceedings of the IEEE*, vol. 80, n.º 12, págs. 1870-1891, 1992. DOI: 10.1109/5.192069.
- [7] G. W. Hart. 0, dirección: <https://www.georgehart.com/research/hartbiog.html>.
- [8] C. Nalmpantis y D. Vrakas, «Machine learning approaches for non-intrusive load monitoring: from qualitative to quantitative comparison», *Artificial Intelligence Review*, vol. 52, n.º 1, págs. 217-243, jun. de 2019, ISSN: 1573-7462. DOI: 10.1007/s10462-018-9613-7. dirección: <https://doi.org/10.1007/s10462-018-9613-7>.
- [9] *El 36% de las casas en España tiene aire acondicionado*, Idealista News, Accessed: 2023-04-15, jul. de 2021. dirección: <https://www.idealista.com/news/inmobiliario/vivienda/2021/07/15/791442-el-36-de-las-casas-en-espana-tiene-aire-acondicionado>.
- [10] A. Toosi, A. Bottino, B. Saboury, E. Siegel y A. Rahmim, «A Brief History of AI: How to Prevent Another Winter (A Critical Review)», *PET Clinics*, vol. 16, sep. de 2021. DOI: 10.1016/j.cpet.2021.07.001.

- [11] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. S. Bernstein, A. C. Berg y L. Fei-Fei, «Image-Net Large Scale Visual Recognition Challenge», *CoRR*, vol. abs/1409.0575, 2014.
- [12] L. E. Baum y T. Petrie, «Statistical Inference for Probabilistic Functions of Finite State Markov Chains», *The Annals of Mathematical Statistics*, vol. 37, n.º 6, págs. 1554-1563, 1966. DOI: 10.1214/aoms/1177699147. dirección: <https://doi.org/10.1214/aoms/1177699147>.
- [13] D. Jurafsky y J. H. Martin, *Speech and Language Processing*. 2023, cap. A. Hidden Markov Models, Copyright © 2023. All rights reserved.
- [14] N. Miquey y E. Grover-Silva, «Non-Intrusive Load Monitoring of Single and Aggregated Profiles with a Hidden Markov Model», en *ENERGY 2021*, Valencia, Spain, mayo de 2021. dirección: <https://minesparis-psl.hal.science/hal-03520223>.
- [15] J. Z. Kolter y T. Jaakkola, «Approximate Inference in Additive Factorial HMMs with Application to Energy Disaggregation», en *Proceedings of the Fifteenth International Conference on Artificial Intelligence and Statistics*, N. D. Lawrence y M. Girolami, eds., ép. Proceedings of Machine Learning Research, vol. 22, La Palma, Canary Islands: PMLR, abr. de 2012, págs. 1472-1482. dirección: <https://proceedings.mlr.press/v22/zicol12.html>.
- [16] B. A. Olshausen y D. J. Field, «Sparse coding with an overcomplete basis set: A strategy employed by V1?», *Vision Research*, vol. 37, n.º 23, págs. 3311-3325, 1997, ISSN: 0042-6989. DOI: [https://doi.org/10.1016/S0042-6989\(97\)00169-7](https://doi.org/10.1016/S0042-6989(97)00169-7). dirección: <https://www.sciencedirect.com/science/article/pii/S0042698997001697>.
- [17] S. University. (). Sparse Coding. Accessed: 2024-04-20, dirección: <http://ufldl.stanford.edu/tutorial/unsupervised/SparseCoding/>.
- [18] S. University. (). Autoencoding Coding. Accessed: 2024-04-20, dirección: <https://ufldl.stanford.edu/tutorial/>.
- [19] M. Xue, S. Kappagoda y D. K. A. Mordecai, *Energy Disaggregation with Semi-supervised Sparse Coding*, 2020. arXiv: 2004.10529 [eess.SP].
- [20] D. Murray, L. Stankovic y V. Stankovic, «An electrical load measurements dataset of United Kingdom households from a two-year longitudinal study», *Scientific Data*, vol. 4, n.º 1, pág. 160 122, 2017, ISSN: 2052-4463. DOI: 10.1038/sdata.2016.122. dirección: <https://doi.org/10.1038/sdata.2016.122>.
- [21] C. Metinko, «Hugging Face Hits 4B Valuation After Salesforce Ventures—Led Round», *Crunchbase News*, 2023. dirección: <https://news.crunchbase.com/ai-robotics/hugging-face-unicorn-salesforce-ventures/>.
- [22] S. Xie, R. Girshick, P. Dollár, Z. Tu y K. He, *Aggregated Residual Transformations for Deep Neural Networks*, 2017. arXiv: 1611.05431 [cs.CV].

- [23] C.-Y. Wang, H.-Y. M. Liao, I.-H. Yeh, Y.-H. Wu, P.-Y. Chen y J.-W. Hsieh, *CSPNet: A New Backbone that can Enhance Learning Capability of CNN*, 2019. arXiv: 1911.11929 [cs.CV].

Anexos

Apéndice A

Glosario

Lista de términos y abreviaciones utilizados en el trabajo. Su sentido es facilitar y familiarizar al lector la comprensión de las abreviaciones.

- NILM: Non Intrusive Load Monitoring - Monitorización de Carga No Intrusiva.
- HMM: Hidden Markov Models - Modelos Ocultos de Markov.
- Sparse Coding: Codificación de escasez.
- CSPNet: Cross Stage Partial Network
- PCA: Principal Component Analysis - Análisis de Componentes Principales

Apéndice B

Repositorios

B.1. Código Fuente

aquí irá mi repositorio, con el readme del repositorio

B.2. Repositorios externos

aquí irán los repositorios que he usado. Actualmente solo he usado el SafeMap