



Universidad Politécnica
de Madrid

**Escuela Técnica Superior de
Ingenieros Informáticos**



Grado en Ingeniería Informática

Trabajo Fin de Grado

**Aplicación de Reconocimiento de
Imágenes para Monitorización de Carga
No Intrusiva**

Autor: Hernán Calvo Aguiar
Tutor(a): Esteban García Cuesta

Madrid, Junio 2023

Este Trabajo Fin de Grado se ha depositado en la ETSI Informáticos de la Universidad Politécnica de Madrid para su defensa.

Trabajo Fin de Grado
Grado en Ingeniería Informática

Título: Aplicación de Reconocimiento de Imágenes para Monitorización
de Carga No Intrusiva

Junio 2023

Autor: Hernán Calvo Aguiar

Tutor: Esteban García Cuesta

Departamento de Inteligencia Artificial (DIA)

Escuela Técnica Superior de Ingenieros Informáticos

Universidad Politécnica de Madrid

Resumen

Aquí va el resumen del trabajo. Extensión máxima 2 páginas.

La Monitorización No Intrusiva de Carga, es una técnica que busca administrar los consumos de diferentes dispositivos eléctricos sin la necesidad de medir directamente cada uno de ellos.

El objetivo de este proyecto es desarrollar la pieza clave de este sistema. Una Inteligencia Artificial que permita identificar los dispositivos conectados y consumiendo a una red eléctrica, como podría ser una casa, un restaurante o una oficina.

El modelo a diseñar deberá ser capaz de identificar los dispositivos conectados a la red eléctrica, y estimar el tiempo de uso de cada uno. Para ello, se ha decidido hacer uso de CSPNet, un modelo potente, computacionalmente barato de entrenar

Este trabajo

Abstract

Abstract of the Final Degree Project. Maximum length: 2 pages.

Tabla de contenidos

1. Introducción	1
1.1. Motivación y Aplicaciones	1
1.2. Objetivos	2
1.3. Alcance del proyecto	2
1.4. Estructura de la Memoria	2
1.5. Planificación	3
1.5.1. Planificación Original	3
1.5.2. Planificación Modificada	3
2. Fundamentos y Panorama Actual	5
2.1. Monitorización de Carga No Intrusiva	5
2.1.1. Modelado y Teoría	5
2.1.2. Modelos de Markov Ocultos	7
2.1.3. Sparse Coding	8
2.1.4. Redes Neuronales	8
2.2. Teoría detrás de la propuesta	8
2.2.1. Dataset PLAID	8
2.2.2. CSPNet	8
2.2.3. Codificación GAF	8
2.2.4. Validación de Modelos: NILMTK	8
3. Desarrollo	9
4. Análisis de impacto	11
5. Conclusiones y trabajo futuro	13
Bibliografía	15
Anexos	19
A. Primer anexo	19

Capítulo 1

Introducción

1.1. Motivación y Aplicaciones

Las técnicas de Monitorización No Intrusiva de Carga (en inglés NILM o Non Intrusive Load Monitoring) extraen el consumo de electrodomésticos a partir de una curva de consumo agregada. [1, pág. 1]. Dicho de otra forma. El monitoreo de carga no intrusivo es un sistema que infiere los consumos de diferentes dispositivos sobre una curva de consumo en la toma de corriente principal. Por ejemplo en la toma de corriente de una casa.

En Europa, un tercio de la energía eléctrica se ha generado mediante energías no renovables(12% o 333TWh carbón, 17% o 569TWh gas natural)[2] [3]. Aún siendo un descenso récord, para poder continuar reduciendo el consumo de energías no renovables, debemos desarrollar herramientas que nos permitan hacer un uso más inteligente de la generación de energía. Herramientas como la monitorización de carga no intrusiva pueden ayudarnos a detectar patrones de uso[4, pág. 11], para entonces poder desarrollar políticas que permitan optimizar la generación de energía.

estimar el ahorro en emisiones si se optimizase el consumo sólo un 2%

Realizar un monitoreo de carga no intrusivo es un problema complejo. Actualmente el área de soluciones NILM se encuentra en la fase de investigación y desarrollo. Por lo tanto. Mi objetivo para este trabajo es entrenar y analizar el rendimiento de una inteligencia artificial especializada en la clasificación de imágenes, transformando los datos de entrenamiento de series temporales a imágenes. Para más detalle, dirigirse al **Capítulo 3**. Quiero ver cómo modificar el enfoque al problema afecta al rendimiento de la técnica en comparación con otras técnicas del estado del arte.

Siguiendo este objetivo y con el asesoramiento de Esteban García Cuesta, se decidió en hacer uso de datasets clasificados para un entrenamiento supervisado; además de una arquitectura potente, compacta y computacionalmente baja en costes de entrenamiento.

1.2. Objetivos

Previamente al comienzo del desarrollo del proyecto, se establecieron una serie de objetivos a cumplir, dividiendo el objetivo final en pasos coherentes y concretos.

1. Investigación del problema NILM (Monitorización de Carga No Intrusiva) y soluciones actuales
2. Elección de dataset con el que se entrenará a la inteligencia artificial.
3. Análisis y calibración del dataset.
4. Desarrollo codificador para transformar las series de datos a imágenes siguiendo la codificación GAF
5. Preprocesado de dataset a través del codificador, para generar tanto las imágenes como sus etiquetas asociadas.
6. Instalación darknet CSPNet, el framework que contiene a CSPNet, la inteligencia artificial que se entrenará.
7. Entrenamiento del modelo. Una prueba de concepto del 10% del dataset y modelo completo, con todo el dataset dedicado a entrenamiento.
8. Análisis del rendimiento del modelo con NILMTK, un toolkit que facilita la comparación del rendimiento con otros modelos.
9. Comparación del rendimiento con otros modelos

1.3. Alcance del proyecto

Al finalizar este proyecto, se busca tener un modelo capaz de realizar una monitorización de carga no intrusiva, además de una serie de programas y herramientas útiles a la hora de realizar trabajos futuros en el área.

1.4. Estructura de la Memoria

La memoria de esta investigación tiene los siguientes capítulos.

- **Introducción:** Se introduce el tema, sus potenciales aplicaciones, motivación, alcance...
- **Fundamentos y Panorama Actual:** Este capítulo sirve para dar al lector una base de la teoría detrás de la tecnología, algoritmos y conceptos sobre los que se desarrolla el trabajo de fin de grado. Además de informar sobre el estado del arte en el área.
- **Desarrollo:** En este capítulo se detallan los pasos tomados para el desarrollo del modelo y las herramientas que utiliza. Entrenamiento, codificación, evaluación del modelo, etc.

- **Análisis de Impacto:** Este apartado recoge los resultados del modelo. Se compara su rendimiento con otros modelos y se habla brevemente del funcionamiento de los modelos contra los que se compara.
- **Conclusiones y Trabajo Futuro:** En este capítulo se recogen las conclusiones del trabajo y el trabajo futuro que puede hacerse para mejorar el modelo y sus partes.
- **Bibliografía:** Se recogen todos los recursos bibliográficos citados durante el transcurso de la investigación.
- **Anexo:** Detalla código e información de interés que no tiene cabida en el cuerpo del texto.

1.5. Planificación

Esta sección recoge la planificación realizada y aprobada por el tutor previa al comienzo del trabajo de fin de grado. Además de la planificación modificada en la entrega de la memoria de seguimiento.

1.5.1. Planificación Original

Figura ?? muestra el diagrama de Gantt de la planificación original.

1.5.2. Planificación Modificada

planificación original, planificacion modificada, modificación diagrama Gantt

Capítulo 2

Fundamentos y Panorama Actual

Capítulo dedicado a describir los fundamentos y el panorama actual del trabajo.

2.1. Monitorización de Carga No Intrusiva

Este concepto fue inventado por George W. Hart, Ed Kern y Fred Schweppe en el Instituto Tecnológico de Massachussets, en los años ochenta [5]. Fundados por el Electric Power Research Institute, podemos encontrar el proceso básico descrito en la patente estadounidense 4,858,141. Una breve bibliografía de George W. Hart: Actualmente ejerce como escultor desde 2017. Tiene esculturas en exposición en Berkeley, Princeton, Cambridge, Duke, Brown... Cofundó el Museo de las Matemáticas y se ha retirado recientemente, trabajó en ciencia computacional, matemáticas, educación e investigación.

2.1.1. Modelado y Teoría

La técnica, descrita por Hart, Kern y Schweppe en su publicación modela los consumos en lo que nombran como "Modelo Total de Carga". El modelo total de carga depende de que dispositivos estén encendidos en un momento dado. Por lo que definen un 'proceso de cambio' $a(t)$ donde a es un dispositivo de consumo eléctrico en un instante de tiempo t . Suponiendo n dispositivos, $a(t)$ será un vector Booleano de n componentes:

$$a_i(t) = \begin{cases} 1, & \text{si dispositivo } i \text{ encendido en } t \\ 0, & \text{si dispositivo } i \text{ apagado en } t \end{cases}$$

Continúan modelando el sistema de potencia total $P(t)$ para un sistema de corriente alterna como el estado de un dispositivo a_i por su consumo P_i con un pequeño ruido o error e

$$P(t) = \sum_{i=1}^n a_i(t)P_i + e(t)$$

Capítulo 2. Fundamentos y Panorama Actual

El criterio para determinar el valor de cada una de los dispositivos es entonces:

$$\hat{a}(t) = \arg \min_a \left| P(t) - \sum_{i=1}^n a_i(t) P_i \right|$$

Esto nos lleva a un problema computacionalmente imposible de resolver salvo mediante la fuerza bruta[5, pág. 4] y poco margen de mejora en el modelado para simplificar su resolución. De manera resumida, el problema trata en encontrar el número de dispositivos y el consumo de cada uno. Este es un problema que se beneficia de hacer uso de modelos heurísticos.

El concepto de NILM desde su introducción ha sido el método preferido por ingenieros e investigadores para la disgregación de consumo desde su introducción, debido a sus ventajas económicas y prácticas.[6, pág. 2, pár. 4]

En cuanto al origen de este método, se buscó categorizar los dispositivos dentro de tres grandes grupos, para poder estructurar los diferentes dispositivos y generalizar el modelado de dispositivos específicos. Estos grupos son:

1. **Señales de estados fijos** Siguen la arquitectura de una máquina de estados finita, las transiciones entre estados son consumos exactos, al igual que los estados
2. **Señales transitorias** Esto son señales que no se encuentran en un espacio discreto que permita modelar su comportamiento como una máquina de estados. Un ejemplo podría ser un calefactor automático, que regula su generación de calor en función de la diferencia de la temperatura ambiente y la temperatura objetivo.
3. **Otras** Señales que no pueden categorizarse en ninguno de los dos casos anteriores. Por ejemplo, los cambios de dirección del motor de una lavadora en el proceso de lavado.

Cabe mencionar que los propios investigadores reconocieron que en el futuro los dispositivos eléctricos que siguiesen un diseño de máquinas de estados perderían precedencia. Ya que habría más 'dispositivos inteligentes'. Actualmente, una calefacción programable o un aire acondicionado programable están al alcance de cualquiera. En 2021, en España el 50 % de las viviendas en alquiler constan de aire acondicionado[7].

Y esto es sólo un dispositivo. Habrá cientos de modelos de cada dispositivo, decenas de marcas, cada dispositivo con sus características específicas. Un modelado exhaustivo sería prácticamente imposible de crear y mantener, ya que sólo para el mercado doméstico hay una cantidad desorbitante de dispositivos, combinaciones de dispositivos, ect.

Debido a estos argumentos, la investigación de la monitorización no intrusiva se inclinó a los modelos heurísticos. De los que voy a destacar los Modelos de Markov Ocultos, el Sparse Coding y finalmente las Redes Neuronales. Siendo estas últimas el foco principal del trabajo, y de este capítulo.

2.1.2. Modelos de Markov Ocultos

Si se sabe la teoría detrás de una cadena de markov, los modelos de Markov Ocultos resultan una dirección intuitiva a tomar, ya que estos representan la probabilidad de transición de un estado a otro.

La Cadena de Markov

Formalmente, una cadena de Markov se representa por los siguientes componentes:

- Un conjunto Q de N estados:

$$Q = q_1 q_2 \dots q_n$$

- Una matriz de probabilidad de transición A donde para cada a_{ij} representando la probabilidad de transicionar desde el estado j al estado i .

$$A = a_{11} a_{12} \dots a_{N1} \dots a_{NN}$$

Cumpliendo A la propiedad: $\sum_{j=1}^n a_{ij} \forall i$

- Una distribución de probabilidad inicial π sobre los estados. Siendo π_i la probabilidad de que la cadena de Markov comience en el estado i .

$$\pi = \pi_1, \pi_2, \dots, \pi_N$$

Si un estado j tuviera $\pi_j = 0$ no podría ser un estado inicial (teniendo probabilidad 0). Además, π debe cumplir $\sum_{i=1}^N \pi_i = 1$

[8]

Identificando Datos Ocultos Con Cadenas de Markov

Una cadena de Markov resulta útil cuando tenemos que modelar un comportamiento en base a una secuencia de eventos observables. El problema, como en NILM, es que los eventos no son directamente observables. Están *ocultos* y por tanto debemos ajustar la cadena para incluir una secuencia de posibles similitudes observadas. Para un elemento i se expresa como $b_i(\theta_t)$ donde θ es derivado de un conjunto de posibles valores observables V

2.1.3. Sparse Coding

2.1.4. Redes Neuronales

Redes Recurrentes

Mapas de atención

Clasificadores de imágenes

2.2. Teoría detrás de la propuesta

2.2.1. Dataset PLAID

2.2.2. CSPNet

2.2.3. Codificación GAF

2.2.4. Validación de Modelos: NILMTK

Capítulo 3

Desarrollo

Capítulo dedicado a describir el desarrollo del trabajo realizado.

- Requisitos (con la especificación de requisitos, ya sea clásico o “agile”)
- Análisis y diseño (con modelo de datos, arquitectura, diseño de experiencia de usuario e interfaz de usuario, etc.)
- Implementación (con detalles sobre la solución/implementación realizada).

Capítulo 4

Análisis de impacto

En este capítulo se realizará un análisis del impacto potencial de los resultados obtenidos durante la realización del trabajo, en los diferentes contextos para los que se aplique:¹

- Personal
- Empresarial
- Social
- Económico
- Medioambiental
- Cultural

En dicho análisis se destacarán los beneficios esperados, así como también los posibles **efectos adversos**. Además, se harán notar aquellas decisiones tomadas a lo largo del trabajo que tienen como base la consideración del impacto.

Se recomienda analizar también el potencial impacto respecto a los Objetivos de Desarrollo Sostenible (ODS), de la Agenda 2030, que sean relevantes para el trabajo realizado (ver enlace)

¹Téngase en cuenta que no se espera que un trabajo tenga impacto en todos los contextos

Capítulo 5

Conclusiones y trabajo futuro

Resumen de resultados obtenidos en el trabajo, conclusiones sobre los mismos y potencial trabajo futuro si existiera.

Bibliografía

- [1] C. Klemenjak y P. Goldsborough, «Non-Intrusive Load Monitoring: A Review and Outlook», *CoRR*, vol. abs/1610.01191, 2016. arXiv: 1610.01191. dirección: <http://arxiv.org/abs/1610.01191>.
- [2] *Shedding light on energy in Europe - 2024 edition - Eurostat*. DOI: 10.2785/88627. dirección: <https://ec.europa.eu/eurostat/web/interactive-publications/energy-2024#about-publication>.
- [3] S. Brown y D. Jones. (2024). *European Electricity Review 2024*, Ember, dirección: <https://ember-climate.org/insights/research/european-electricity-review-2024/>.
- [4] J. Revuelta Herrero, Á. Lozano Murciego, A. Barriuso, D. Hernández de la Iglesia, G. Villarrubia, J. Corchado Rodríguez y R. Carreira, «Non Intrusive Load Monitoring (NILM): A State of the Art», jun. de 2018, págs. 125-138, ISBN: 978-3-319-61577-6. DOI: 10.1007/978-3-319-61578-3_12.
- [5] G. Hart, «Nonintrusive appliance load monitoring», *Proceedings of the IEEE*, vol. 80, n.º 12, págs. 1870-1891, 1992. DOI: 10.1109/5.192069.
- [6] C. Nalmpantis y D. Vrakas, «Machine learning approaches for non-intrusive load monitoring: from qualitative to quantitative comparison», *Artificial Intelligence Review*, vol. 52, n.º 1, págs. 217-243, jun. de 2019, ISSN: 1573-7462. DOI: 10.1007/s10462-018-9613-7. dirección: <https://doi.org/10.1007/s10462-018-9613-7>.
- [7] *El 36% de las casas en España tiene aire acondicionado*, Idealista News, Accessed: 2023-04-15, jul. de 2021. dirección: <https://www.idealista.com/news/inmobiliario/vivienda/2021/07/15/791442-el-36-de-las-casas-en-espana-tiene-aire-acondicionado>.
- [8] D. Jurafsky y J. H. Martin, *Speech and Language Processing*. 2023, cap. A. Hidden Markov Models, Copyright © 2023. All rights reserved.

Anexos

Apéndice A

Primer anexo

Este capítulo (anexo) es opcional, y se escribirá de acuerdo con las indicaciones del Tutor.