



Universidad Politécnica
de Madrid

**Escuela Técnica Superior de
Ingenieros Informáticos**



Grado en Ingeniería Informática

Trabajo Fin de Grado

**Aplicación de Reconocimiento de
Imágenes para Monitorización No
Intrusiva de Carga Eléctrica**

Autor: Hernán Calvo Aguiar
Tutor(a): Esteban García Cuesta

Madrid, Junio 2024

Este Trabajo Fin de Grado se ha depositado en la ETSI Informáticos de la Universidad Politécnica de Madrid para su defensa.

Trabajo Fin de Grado
Grado en Ingeniería Informática

Título: Aplicación de Reconocimiento de Imágenes para Monitorización
No Intrusiva de Carga Eléctrica

Junio 2024

Autor: Hernán Calvo Aguiar

Tutor: Esteban García Cuesta

Departamento de Inteligencia Artificial (DIA)

Escuela Técnica Superior de Ingenieros Informáticos

Universidad Politécnica de Madrid

Resumen

Aquí va el resumen del trabajo. Extensión máxima 2 páginas.

La Monitorización No Intrusiva de Carga, es una técnica que busca administrar los consumos de diferentes dispositivos eléctricos sin la necesidad de medir directamente cada uno de ellos.

El objetivo de este proyecto es desarrollar la pieza clave de este sistema. Una Inteligencia Artificial que permita identificar los dispositivos conectados y consumiendo a una red eléctrica, como podría ser una casa, un restaurante o una oficina.

El modelo a diseñar deberá ser capaz de identificar los dispositivos conectados a la red eléctrica, y estimar el tiempo de uso de cada uno. Para ello, se ha decidido hacer uso de CSPNet, un modelo potente, computacionalmente barato de entrenar

Este trabajo

Abstract

Abstract of the Final Degree Project. Maximum length: 2 pages.

Tabla de contenidos

| | |
|--|-----------|
| 1. Introducción | 1 |
| 1.1. Motivación y Aplicaciones | 1 |
| 1.2. Objetivos | 2 |
| 1.3. Alcance del proyecto | 2 |
| 1.4. Estructura de la Memoria | 3 |
| 2. Fundamentos y Estado del Arte | 5 |
| 2.1. Conceptos generales | 5 |
| 2.2. Aprendizaje Automático | 7 |
| 2.3. Redes Neuronales | 9 |
| 2.3.1. Sparse Coding | 9 |
| 2.3.2. Clasificadores de imágenes | 10 |
| 2.3.3. Redes Recurrentes | 10 |
| 2.4. | 10 |
| 2.4.1. CSPNet | 10 |
| 2.4.2. Codificación GAF | 10 |
| 2.4.3. Validación de Modelos: NILMTK | 10 |
| 3. Desarrollo | 11 |
| 3.1. Planificación | 11 |
| 3.2. REFIT Dataset | 11 |
| 3.2.1. Características principales | 11 |
| 3.2.2. Pros y contras del dataset | 12 |
| 3.3. Parseado de REFIT a MySQL | 13 |
| 3.3.1. Inconvenientes | 13 |
| 3.3.2. Modelo de la BBDD | 13 |
| 3.3.3. Herramientas desarrolladas | 13 |
| 3.4. Codificación GAF | 14 |
| 3.4.1. Justificación del uso de OpenCL | 14 |
| 3.4.2. Inconvenientes | 14 |
| 3.4.3. Solución | 14 |
| 3.5. Entrenamiento | 14 |
| 3.5.1. ZLUDA y Darknet Framework | 14 |
| 3.5.2. Monitorización | 14 |
| 3.5.3. Inconvenientes | 14 |
| 4. Resultados y Análisis de Impacto | 15 |

TABLA DE CONTENIDOS

| | |
|--|-----------|
| 4.1. Resultados | 15 |
| 4.2. Impacto | 15 |
| 4.2.1. Personal | 15 |
| 4.2.2. Empresarial | 15 |
| 4.2.3. Económico | 15 |
| 4.2.4. Medioambiental | 15 |
| 5. Conclusiones y trabajo futuro | 17 |
| 5.1. Conclusiones | 17 |
| 5.2. Trabajo a Futuro | 17 |
| 5.3. Alegato Final | 17 |
| Bibliografía | 19 |
| Anexos | 23 |
| A. Glosario | 23 |
| B. Fórmulas Matemáticas | 25 |
| B.1. Cadenas de Markov y Modelos Ocultos de Markov | 25 |
| B.2. Modelos Factoriales Ocultos de Markov | 25 |
| B.3. Sparse Coding | 25 |
| C. Repositorios | 27 |
| C.1. Código Fuente | 27 |
| C.2. Repositorios externos | 27 |

Capítulo 1

Introducción

1.1. Motivación y Aplicaciones

Las técnicas de Monitorización No Intrusiva de Carga (en inglés NILM o Non Intrusive Load Monitoring) extraen el consumo de electrodomésticos a partir de una curva de consumo agregada. [1, pág. 1]. Dicho de otra forma. El monitoreo de carga no intrusivo es un sistema que infiere los consumos de diferentes dispositivos sobre una curva de consumo en la toma de corriente principal. Por ejemplo en la toma de corriente de una casa.

En Europa, un tercio de la energía eléctrica se ha generado mediante energías no renovables(12 % o 333TWh carbón, 17 % o 569TWh gas natural)[2] [3]. Aún siendo un descenso récord, para poder continuar reduciendo el consumo de energías no renovables, debemos desarrollar herramientas que nos permitan hacer un uso más inteligente de la generación de energía. Herramientas como la monitorización de carga no intrusiva pueden ayudarnos a detectar patrones de uso[4, pág. 11], para entonces poder desarrollar políticas que permitan optimizar la generación de energía.

Si, hipotéticamente, se redujese un 2 % la generación de electricidad a través de la combustión de carbón. Supondría una reducción de emisiones de 96.6 Millones de Toneladas de CO₂¹.

Realizar un monitoreo de carga no intrusivo es un problema complejo. Actualmente el área de soluciones NILM se encuentra en la fase de investigación y desarrollo. Por lo tanto. Mi objetivo para este trabajo es entrenar y analizar el rendimiento de una inteligencia artificial especializada en la clasificación de imágenes, transformando los datos de entrenamiento de series temporales a imágenes. Detallado en el **Capítulo 3**. El trabajo se centrará en cómo modificar el enfoque al problema de disgregación de consumos afecta al rendimiento de la técnica en comparación con otras técnicas del estado del arte.

Este concepto fue inventado por George W. Hart, Ed Kern y Fred Schweppe en

¹ $333 * 10^3 \text{GWh} * 290 \frac{\text{tCO}_2}{\text{GWh}}$ [5]

Capítulo 1. Introducción

el Instituto Tecnológico de Massachussets, en los años ochenta [6]. Fundados por el Electric Power Research Institute, podemos encontrar el proceso básico descrito en la patente estadounidense 4,858,141.

Una breve bibliografía de George W. Hart: Actualmente ejerce como escultor desde 2017. Tiene esculturas en exposición en Berkeley, Princeton, Cambridge, Duke, Brown... Cofundó el único Museo de las Matemáticas en Norteamérica y se ha retirado recientemente, trabajó en ciencia computacional, matemáticas, educación e investigación [7].

La técnica, descrita por Hart, Kern y Schweppe en [6] modela los consumos en lo que nombran como "Modelo Total de Carga". El modelo total de carga depende de que dispositivos estén encendidos en un momento dado. Por lo que definen un 'proceso de cambio'. Esto nos lleva a un problema computacionalmente imposible de resolver salvo mediante la fuerza bruta[6, pág. 4] y poco margen de mejora en el modelado para simplificar su resolución. De manera resumida, el problema trata en encontrar el número de dispositivos y el consumo de cada uno. Este es un problema que se beneficia de hacer uso de modelos heurísticos.

Siguiendo este objetivo y con el asesoramiento de Esteban García Cuesta, se decidió en hacer uso de datasets clasificados para un entrenamiento supervisado; además de una arquitectura potente, compacta y computacionalmente baja en costes de entrenamiento.

extender motivación y aplicaciones, introducir con más detalle el problema y citar más motivaciones

1.2. Objetivos

Previamente al comienzo del desarrollo del proyecto, se establecieron una serie de objetivos a cumplir, dividiendo el objetivo final en pasos coherentes y concretos. En esta sección se detallan los objetivos de aprendizaje e investigación:

Este trabajo busca investigar sobre las técnicas más actuales en NILM². Dando al lector una base de las técnicas utilizadas en el estado del arte y las matemáticas detrás de estas técnicas. Los objetivos de aprendizaje son extensos, el trabajo busca además profundizar en la práctica detrás de el entrenamiento de una inteligencia artificial y de los retos que presenta el uso de la computación paralela, bases de datos, GPUs, lenguajes de bajo nivel (C++, OpenCL) y el uso de frameworks de creación, entrenamiento y análisis del rendimiento de la inteligencia artificial.

1.3. Alcance del proyecto

Al finalizar este proyecto, se busca tener un modelo capaz de realizar una monitorización de carga no intrusiva, además de una serie de progamas y herramientas útiles a la hora de realizar trabajos futuros en el área.

²ver Apéndice A

1.4. Estructura de la Memoria

La memoria de esta investigación tiene los siguientes capítulos.

- **Introducción:** Se introduce el tema, sus potenciales aplicaciones, motivación, alcance...
- **Fundamentos y Panorama Actual:** Este capítulo sirve para dar al lector una base de la teoría detrás de la tecnología, algoritmos y conceptos sobre los que se desarrolla el trabajo de fin de grado. Además de informar sobre el estado del arte en el área.
- **Desarrollo:** En este capítulo se detallan los pasos tomados para el desarrollo del modelo y las herramientas que utiliza. Entrenamiento, codificación, evaluación del modelo, etc.
- **Resultados y Análisis de Impacto:** Este apartado recoge los resultados del modelo y se compara su rendimiento con otros modelos. Además recoge el análisis del impacto del modelo conforme a los Objetivos de Desarrollo Sostenible de la Agenda 2030.
- **Conclusiones y Trabajo Futuro:** En este capítulo se recogen las conclusiones del trabajo y el trabajo futuro que puede hacerse para mejorar el modelo y sus partes.
- **Bibliografía:** Se recogen todos los recursos bibliográficos citados durante el transcurso de la investigación.
- **Anexo:** Detalla código e información de interés que no tiene cabida en el cuerpo del texto.

Capítulo 2

Fundamentos y Estado del Arte

Capítulo dedicado a describir los fundamentos y el panorama actual del trabajo.

2.1. Conceptos generales

El concepto de NILM desde su introducción ha sido el método preferido por ingenieros e investigadores para la disgregación de consumo eléctrico desde su introducción, debido a sus ventajas económicas y prácticas.[8, pág. 2, pár. 4]

En cuanto al origen de este método, se buscó categorizar en [6] los dispositivos dentro de tres grandes grupos, para poder estructurar los diferentes dispositivos y generalizar el modelado de dispositivos específicos. Estos grupos son:

1. **Señales de estados fijos** Siguen la arquitectura de una máquina de estados finita, las transiciones entre estados son consumos exactos, al igual que los estados
2. **Señales transitorias** Esto son señales que no se encuentran en un espacio discreto que permita modelar su comportamiento como una máquina de estados. Un ejemplo podría ser un calefactor automático, que regula su generación de calor en función de la diferencia de la temperatura ambiente y la temperatura objetivo.
3. **Otras** Señales que no pueden categorizarse en ninguno de los dos casos anteriores. Por ejemplo, los cambios de dirección del motor de una lavadora en el proceso de lavado.

Cabe mencionar que los propios investigadores reconocieron que en el futuro los dispositivos eléctricos que siguiesen un diseño de máquinas de estados perderían precedencia. Ya que habría más 'dispositivos inteligentes' [6]. Actualmente, una calefacción programable o un aire acondicionado programable están al alcance de cualquiera. En 2021, en España el 50 % de las viviendas en alquiler constan de aire acondicionado[9].

Y esto es sólo un dispositivo. Habrá cientos de modelos de cada dispositivo, decenas de marcas, cada dispositivo con sus características específicas. Un mo-

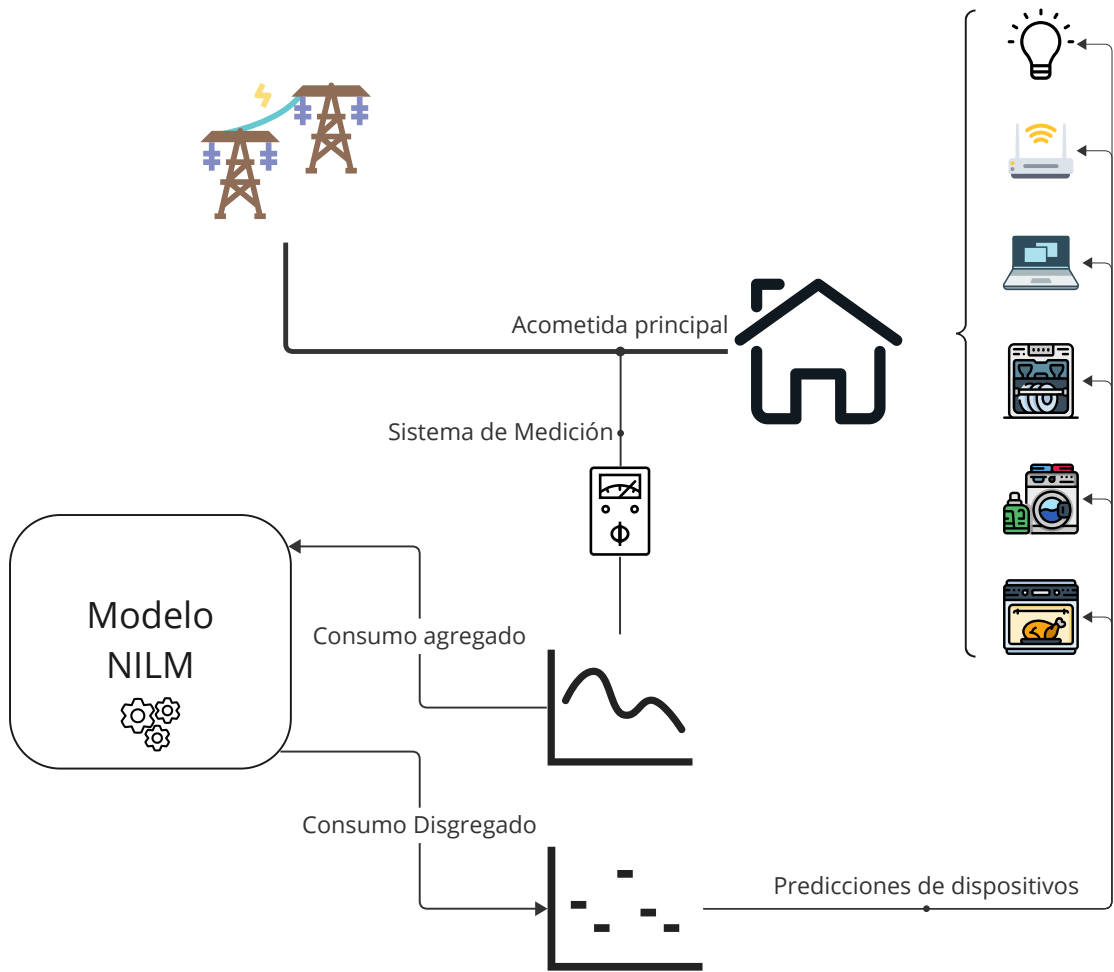


Figura 2.1: Un diagrama simple de un sistema NILM

delado exhaustivo sería prácticamente imposible de crear y mantener, ya que sólo para el mercado doméstico hay una cantidad desorbitante de dispositivos, combinaciones de dispositivos, etc.

Un ejemplo de sistema NILM Un sistema NILM consta de las siguientes partes: Una fuente de datos (acometida principal). Un dispositivo de recogida de datos (puede ser de Potencia Activa Y reactiva, Voltaje e Intensidad, etc). El modelo predictivo. Y el sistema de consulta de datos, que se ha omitido en la Figura 2.1.

Debido a estos argumentos, la investigación de la monitorización no intrusiva se inclinó a los modelos heurísticos y el aprendizaje automático.

2.2. Aprendizaje Automático

En la Historia de la Inteligencia Artificial, se han definido una serie de etapas de gran crecimiento y financiación como "veranos"(tres concretamente). Alternados por (dos) "inviernos"; donde el interés, la financiación y el número de publicaciones decrecían significativamente [10]. En los principios de la década de los 2010, comenzó el tercer "verano" de la Inteligencia Artificial. En 2012 ocurre un avance técnico: unos años antes, Olga Russakovsky creó el reto ImageNet [11]; un repositorio de más de un millón de imágenes de objetos a lo largo de más de mil categorías diferentes. Este reto estimuló a la comunidad científica,

Resulta lógico que el número de artículos científicos proponiendo modelos que permitiesen resolver los retos que presenta NIML aumentase.

De los que voy a destacar los Modelos Ocultos de Markov, el Sparse Coding y finalmente las Redes Neuronales. Siendo estas últimas el foco principal del trabajo, y de este capítulo.

Si se sabe la teoría detrás de una cadena de markov, los modelos de Markov Ocultos resultan una dirección intuitiva a tomar, ya que estos representan la probabilidad de transición de un estado a otro. En esta subsección daremos una breve introducción a la teoría detrás de este modelo probabilístico.

La Cadena de Markov

Formalmente, una cadena de Markov se representa por los siguientes componentes:

- Un conjunto Q de N estados:

$$Q = q_1 q_2 \dots q_n$$

- Una matriz de probabilidad de transición A donde para cada a_{ij} representando la probabilidad de transicionar desde el estado j al estado i .

$$A = a_{11} a_{12} \dots a_{N1} \dots a_{NN}$$

Cumpliendo A la propiedad: $\sum_{j=1}^n a_{ij} \forall i$

- Una distribución de probabilidad inicial π sobre los estados. Siendo π_i la probabilidad de que la cadena de Markov comience en el estado i .

$$\pi = \pi_1, \pi_2, \dots, \pi_N$$

Si un estado j tuviera $\pi_j = 0$ no podría ser un estado inicial (teniendo probabilidad 0).

Además, π debe cumplir $\sum_{i=1}^N \pi_i = 1$

[12]

Identificando Datos Ocultos Con Cadenas de Markov

Una cadena de Markov resulta útil cuando tenemos que modelar un comportamiento en base a una secuencia de eventos observables, siendo L.E. Baum y Ted Petrie los autores de [13], el primero de una serie de papers sobre modelos probabilísticos y estadística que introdujeron los HMM. Estos eventos observables son elementos conocidos, pero la secuencia de estados del modelo para esos eventos observables son desconocidos.

El problema, como en NILM, es que los estados no son directamente observables. Estan *ocultos* y por tanto debemos ajustar la cadena para incluir una secuencia de posibles similitudes observadas [12].

Continuando la explicación de la subsección anterior:

- Para un elemento i se expresa como $b_i(o)$ donde o es derivado de un conjunto de posibles valores observables V .

- Dado:

$$Q = q_1 q_2 \dots q_n$$

- Calculamos la probabilidad de una cadena de estados S de longitud T

$$S = s_1, s_2, \dots, s_T$$

- Dado un conjunto de valores observados

$$O = o_1, o_2, \dots, o_T$$

para T observaciones.

[12]

Resumiendo: dados una serie de eventos observables, podemos inferir la probabilidad de cada estado que causaron estos eventos observables: Calculando la probabilidad de una cadena de eventos observables dada la probabilidad de una cadena de estados del conjunto, para todas las posibles combinaciones de la cadena los estados del conjunto. Este algoritmo se conoce algoritmo de Viterbi. Siendo la fórmula:

$$[12] \arg \max_{O=o_1, o_2, \dots, o_T} P(O = o_1, o_2, \dots, o_T | S = s_1, s_2, \dots, s_T)$$

Este es el modelado que nos permite inferir de manera probabilística (fórmulas en detalle podrán encontrarse en el **Apéndice B**) Cabe añadir que las cadenas de markov tienen una serie de algoritmos para determinar la cadena de estados ocultos más probable para la cadena de eventos observables, se omite por brevedad, pero puede consultarse [12] para una excelente y detallada explicación sobre este área.

se añadirá el
anexo para la
entrega de la
memoria final

Modelos Ocultos de Markov

Explicadas brevemente las bases de los Modelos Ocultos de Markov, pasamos a la aplicación de este modelo estadístico en la disgregación de consumos.

Dado que un modelo de markov oculto infiere probabilísticamente una serie de estados, esto nos resulta útil para la disgregación de dispositivos. Para codificar diferentes estados de diferentes dispositivos se aumenta el número de cadenas del modelo. Teniendo una matriz de estados S_i^j donde S es un conjunto de estados; las observaciones dependen de todos los estados en un momento dado. Podemos observar esto en el siguiente diagrama:

Observando el diagrama b) no resulta muy complicado imaginar la utilidad de este modelo. Si cada cadena representa un dispositivo modelado en diferentes estados, resulta un diseño muy apropiado para NILM. Los Modelos de Markov Ocultos se han tratado en la literatura como efectivos en comparación con otras técnicas de monitorización cuando el entrenamiento supervisado presenta una baja tasa de muestreo en el eje temporal de la obtención de datos [14]. Otras ventajas que presenta es su bajo coste computacional en el entrenamiento. Pero el uso de este tipo de elementos lo vuelven altamente susceptible a máximos locales[1].

En el caso de los Modelos Factoriales de Markov Ocultos (con siglas FHMM en inglés), presentan ciertas ventajas en comparación con los HMM ¹: La complejidad y el coste computacional de los algoritmos de aprendizaje e inferencia son menores para los HMM. Sin embargo, tanto FHMM como HMM presentan limitaciones al volumen máximo de dispositivos simultáneos, incluso en casos como [15] donde se propone un nuevo algoritmo no supervisado. El algoritmo desarrollado (AFMAP) no presenta los problemas de alta complejidad y máximos locales, pero requiere de etiquetación manual después de la disgregación. Y presenta bajo rendimiento para dispositivos electrónicos y de cocina [1, pág. 5].

2.3. Redes Neuronales

En esta sección se tratan tres conceptos de las Redes Neuronales; se dará una introducción y se expondrán las aplicaciones pertinentes al tema del proyecto. Por motivos de brevedad, se asume que el lector tiene una cierta base en inteligencia artificial. En caso contrario, sugiero consultar las citas y el Apéndice A

2.3.1. Sparse Coding

Breve Introducción

Introducido por Olshausen et al., 1997 [16]. El Sparse Coding consiste en reducir la activación de la capa oculta de las neuronas, forzando a la red neuronal a realizar un aprendizaje [17]. Su objetivo es encontrar un conjunto de vectores ϕ_i tal que podamos representar un vector x como una combinación lineal de estos

¹Hidden Markov Models, o en español los Modelos Ocultos de Markov

vectores:

$$x = \sum_{i=1}^k a_i \phi_i$$

Este es un concepto que está fuertemente relacionado con los autoencoders y el aprendizaje PCA.

Que tienen como objetivo es que su salida sea igual a la entrada, pero limitando la capa oculta para forzar un aprendizaje [18]. Por ejemplo, supongamos que buscásemos utilizar un autoencoder para comprimir una imagen para enviarla por internet. Si no implementásemos restricciones, dado que el objetivo de la red neuronal es reducir la pérdida de información a 0; la salida del autoencoder sería la imagen, completamente idéntica.

Para evitar esto en el caso de los autoencoders se introduce una capa oculta de menor tamaño en comparación a la capa de entrada como restricción para forzar un aprendizaje, al tener una capa oculta, la capa de salida (de igual tamaño a la de entrada) debe reconstruir la entrada [18].

Volviendo al Sparse Coding. Al tener un conjunto de vectores sobrecompleto, los coeficientes a_i ya no se determinan únicamente por el vector de entrada x . Luego se define una función de escasez². Definimos esta función de escasez como: tener los menos componentes (a_i) distintos de cero o el mínimo de componentes no cerca de cero [17].

Aplicaciones

Tanto los autoencoders como el sparse coding han sido usados en la literatura NILM. sparse coding:[19]

Pendiente continuar investigando

2.3.2. Clasificadores de imágenes

2.3.3. Redes Recurrentes

2.4.

2.4.1. CSPNet

2.4.2. Codificación GAF

2.4.3. Validación de Modelos: NILMTK

²De ahí el "Sparse"; escasez en Español

Capítulo 3

Desarrollo

TODOS LOS DIAGRAMAS SE HARAN CON MIRO, EXPORTADOS A SVG E INTEGRADOS

3.1. Planificación

Se realizó dos tandas de organización y planificación de tareas. La primera al principio del semestre y la segunda a mediados de abril. Las dificultades en la planificación fueron una combinación de motivos externos y una perspectiva algo ingenua del tiempo a invertir y el ritmo de progreso. Debido a la falta de conocimientos, se ha dedicado un tiempo considerable (unas 60-80 horas) a realizar investigación y estudio, para poder comprender las técnicas y modelos implementados el estado del arte.

En lo que respecta al desarrollo, se han dedicado unas 80-100 horas.

Los principales problemas fueron: la dificultad para programar un codificador en C++ y OpenCL, debido a la curva de dificultad que representa aprender un lenguaje para una nueva arquitectura y los retos que presenta la gran cantidad de datos usada para el entrenamiento de inteligencia artificial.

3.2. REFIT Dataset

Tras una investigación de los potenciales datasets, se decidió usar como dataset REFIT. El nombre completo del dataset es "Personalised Retrofit Decision Support Tools For UK Homes Using Smart Home Technology"[20].

3.2.1. Características principales

Puede encontrarse todo el detalle sobre el dataset en [20].

El dataset recoge datos de 20 casas durante un periodo continuo de dos años, con un periodo de medición superior a un minuto entre mediciones para todas las casas. Siendo este el único dataset de Gran Bretaña con estas características.

Capítulo 3. Desarrollo

Se miden 9 dispositivos además del consumo agregado. Todas las mediciones se realizaron en vatios.

aquí va la infraestructura de medición

El dataset ocupa unos 5GB de memoria, se presentan todas las mediciones de una sola casa en archivos CSV. Siguiendo la distribución:

Time, Unix, Aggregate, Appliance1, ... , Appliance9, Issues

Habiendo 21 archivos en total que recogen datos, y un vigésimo segundo archivo conteniendo los metadatos de cada casa. Estos metadatos se limitan a especificar el tipo de dispositivo asociado al dispositivo o *Appliance*

añadir unas líneas de una casa y una y sus metadatos

En cuanto a la recogida de datos, se definió un periodo de recogida de datos de ocho segundos. Por tanto los datos se recogieron con un desplazamiento temporal. Esto quiere decir que los datos de los dispositivos y el agregado no coinciden exactamente en el tiempo, habiendo una diferencia de unos segundos entre dispositivo y dispositivo. El acumulado (o agregado) se calculaba antes de que finalizase el periodo de ocho segundos.

3.2.2. Pros y contras del dataset

Las ventajas de este dataset son, su longitud en el tiempo y la facilidad de empezar a hacer un uso de los mismos. Ya que se busca investigar sobre la viabilidad de un modelo que haga uso de clasificadores de imágenes, esto habilita la posibilidad de realizar un trabajo de fin de grado con este tema.

Hay una serie de problemas conocidos sobre el dataset. En la publicación asociada se mencionan los siguientes:

- Ocasionalmente los medidores de dispositivos reportaban consumos muy por encima de la carga máxima para un dispositivo de uso doméstico. Estas medidas se eliminaron del dataset.
- Hubo problemas con la sincronización temporal de los medidores de dispositivos. Esto conlleva discrepancias entre el agregado y las mediciones.
- Las mediciones del acumulado en casas 3, 11 y 21 se vieron afectadas debido a que los domicilios contaban con paneles solares, y recablear para evitar afectar a las medidas del acumulado no era posible.
- En algunos casos, los valores entre acumulado y dispositivos no coinciden debido a que no se monitorizaron otras variables para ajustar estas medidas conforme el ángulo de fase o el voltaje por cargas inductivas o capacitivas.

Debido a estos problemas, los datos de las casas 3, 11 y 21 no serán utilizados. Además, debido a falta de clasificación en los metadatos, las casas tampoco fueron utilizados para el entrenamiento.

poner las casas que no dan datos

3.3. Parseado de REFIT a MYSQL

Como primer paso, se decidió parsear todos los datos a una BBDD, escogiendo MYSQL como plataforma, para tener una lógica de acceso que permitiese ordenar los datos para su codificación conforme a diferentes algoritmos (secuencial, k-means) para poder extraer la mayor cantidad de características sobre los dispositivos en diferentes marcos temporales.

3.3.1. Inconvenientes

La inserción de datos en la base de datos fue tremendamente lenta. Para insertar un CSV entero, se tardaba en el peor de los casos cerca de las 72h de inserción continuada. En parte esto se debe a que se mantuvo durante un tiempo la configuración del servidor MYSQL *out of the box* sin realizar ningún cambio. Más adelante se investigó cómo poder optimizar las inserciones, pero no se consiguió ninguna mejora destacable. A posteriori, podría haberse investigado utilizar otra herramienta que no requiriese de insertar por fuerza bruta.

3.3.2. Modelo de la BBDD

Para este paso del desarrollo, se decidió un modelo simple, imitando la presentación de los datos en el csv.

aquí modelo de la base de datos en su primer modelo

3.3.3. Herramientas desarrolladas

Para la inserción, se diseñaron dos programas en C++. Haciendo uso de la librería de conector de C++ a mysql. Se seleccionaba el archivo manualmente y comenzaba la inserción. Una vez iniciada la inserción de datos, esta se paraba en la misma fecha, el 31 de marzo. Esto se debía a que al insertar la fecha, habiendo un cambio de hora esa madrugada, las fechas no coincidían con las esperadas.

La solución a este problema fue desarrollar un programa que permitiese saltar a la línea donde daba el fallo, además de una serie de herramientas para "debuggear" la inserción de datos, pudiendo saltar a una línea específica e insertar manualmente o continuar la inserción.

aquí una demostración de la herramienta

Además de desarrollar el programa, se cambió la configuración de fechas en el servidor MYSQL.

```
SELECT @@global.time_zone, @@session.time_zone;
SET GLOBAL time_zone = '+00:00';
SET SESSION time_zone = '+00:00';
```

Hablar de porqué lo parseamos a mysql, los inconvenientes (zona horaria e interrupciones en el parseo) y el diseño realizado para resolver estos problemas, además de los programas desarrollados (el primero que se rompía y el segundo que es traversecsv.cpp)

3.4. Codificación GAF

3.4.1. Justificación del uso de OpenCL

3.4.2. Inconvenientes

3.4.3. Solución

Hablar de porqué se decidió usar opencl, porqué se retrasó tanto esta parte del proyecto el diseño que era muy bueno pero muy complicado de implementar

3.5. Entrenamiento

3.5.1. ZLUDA y Darknet Framework

3.5.2. Monitorización

3.5.3. Inconvenientes

Apartado pendiente

Capítulo 4

Resultados y Análisis de Impacto

4.1. Resultados

Resultados del modelo, comparación con otros modelos.

4.2. Impacto

4.2.1. Personal

Mayor control de gasto, menos privacidad. Análisis de patrones de gastos y por tanto hábitos personales/de la vivienda

4.2.2. Empresarial

industria: mayor control y más barato. (explicar pq) del gasto energético

4.2.3. Económico

mejora de la gestión energética lleva a mayor eficiencia, optimización y a mejor aprovechamiento de las energías renovables

4.2.4. Medioambiental

pro: aprovechar el consumo/optimizar los patrones de gasto teniendo mayor granularidad y un modelo inferente como el que se ha desarrollado permite construir en un futuro herramientas predictivas de gastos que por tanto pueden aportar info valiosa para modelos más generales (usando estos y otros datos como los meteorológicos, mercantiles, mercados, etc) para estimar la demanda esperada y el volumen de energía a generar.

Se recomienda analizar también el potencial impacto respecto a los Objetivos de Desarrollo Sostenible (ODS), de la Agenda 2030, que sean relevantes para el trabajo realizado (ver enlace)

Capítulo 5

Conclusiones y trabajo futuro

5.1. Conclusiones

5.2. Trabajo a Futuro

5.3. Alegato Final

Bibliografía

- [1] A. Faustine, N. H. Mvungi, S. F. Kaijage y M. Kisangiri, «A Survey on Non-Intrusive Load Monitoring Methodies and Techniques for Energy Disaggregation Problem», *CoRR*, vol. abs/1703.00785, 2017.
- [2] *Shedding light on energy in Europe - 2024 edition - Eurostat*. DOI: 10.2785/88627. dirección: <https://ec.europa.eu/eurostat/web/interactive-publications/energy-2024#about-publication>.
- [3] S. Brown y D. Jones. (2024). *European Electricity Review 2024*, Ember, dirección: <https://ember-climate.org/insights/research/european-electricity-review-2024/>.
- [4] J. Revuelta Herrero, Á. Lozano Murciego, A. Barriuso, D. Hernández de la Iglesia, G. Villarrubia, J. Corchado Rodríguez y R. Carreira, «Non Intrusive Load Monitoring (NILM): A State of the Art», jun. de 2018, págs. 125-138, ISBN: 978-3-319-61577-6. DOI: 10.1007/978-3-319-61578-3_12.
- [5] J. C. Romero Mora, *Anyone know a scientific reference about converting kwh electricity to CO2 emission?*, dic. de 2014. dirección: <https://www.researchgate.net/post/Anyone-know-a-scientific-reference-about-converting-kwh-electricity-to-CO2-emission#:~:text=In%202013%2C%20it%20was%200%2C29%C2%A0Kt%20CO2/GWh>.
- [6] G. Hart, «Nonintrusive appliance load monitoring», *Proceedings of the IEEE*, vol. 80, n.º 12, págs. 1870-1891, 1992. DOI: 10.1109/5.192069.
- [7] G. W. Hart. (), dirección: <https://www.georgehart.com/research/hartbiog.html>.
- [8] C. Nalmpantis y D. Vrakas, «Machine learning approaches for non-intrusive load monitoring: from qualitative to quantitative comparison», *Artificial Intelligence Review*, vol. 52, n.º 1, págs. 217-243, jun. de 2019, ISSN: 1573-7462. DOI: 10.1007/s10462-018-9613-7. dirección: <https://doi.org/10.1007/s10462-018-9613-7>.
- [9] *El 36% de las casas en España tiene aire acondicionado*, Idealista News, Accessed: 2023-04-15, jul. de 2021. dirección: <https://www.idealista.com/news/inmobiliario/vivienda/2021/07/15/791442-el-36-de-las-casas-en-espana-tiene-aire-acondicionado>.
- [10] A. Toosi, A. Bottino, B. Saboury, E. Siegel y A. Rahmim, «A Brief History of AI: How to Prevent Another Winter (A Critical Review)», *PET Clinics*, vol. 16, sep. de 2021. DOI: 10.1016/j.cpet.2021.07.001.

- [11] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. S. Bernstein, A. C. Berg y L. Fei-Fei, «Image-Net Large Scale Visual Recognition Challenge», *CoRR*, vol. abs/1409.0575, 2014.
- [12] D. Jurafsky y J. H. Martin, *Speech and Language Processing*. 2023, cap. A. Hidden Markov Models, Copyright © 2023. All rights reserved.
- [13] L. E. Baum y T. Petrie, «Statistical Inference for Probabilistic Functions of Finite State Markov Chains», *The Annals of Mathematical Statistics*, vol. 37, n.º 6, págs. 1554-1563, 1966. DOI: 10.1214/aoms/1177699147. dirección: <https://doi.org/10.1214/aoms/1177699147>.
- [14] N. Miquey y E. Grover-Silva, «Non-Intrusive Load Monitoring of Single and Aggregated Profiles with a Hidden Markov Model», en *ENERGY 2021*, Valencia, Spain, mayo de 2021. dirección: <https://minesparis-psl.hal.science/hal-03520223>.
- [15] J. Z. Kolter y T. Jaakkola, «Approximate Inference in Additive Factorial HMMs with Application to Energy Disaggregation», en *Proceedings of the Fifteenth International Conference on Artificial Intelligence and Statistics*, N. D. Lawrence y M. Girolami, eds., ép. Proceedings of Machine Learning Research, vol. 22, La Palma, Canary Islands: PMLR, abr. de 2012, págs. 1472-1482. dirección: <https://proceedings.mlr.press/v22/zicol12.html>.
- [16] B. A. Olshausen y D. J. Field, «Sparse coding with an overcomplete basis set: A strategy employed by V1?», *Vision Research*, vol. 37, n.º 23, págs. 3311-3325, 1997, ISSN: 0042-6989. DOI: [https://doi.org/10.1016/S0042-6989\(97\)00169-7](https://doi.org/10.1016/S0042-6989(97)00169-7). dirección: <https://www.sciencedirect.com/science/article/pii/S0042698997001697>.
- [17] S. University. (). Sparse Coding. Accessed: 2024-04-20, dirección: <http://ufldl.stanford.edu/tutorial/unsupervised/SparseCoding/>.
- [18] S. University. (). Autoencoding Coding. Accessed: 2024-04-20, dirección: <https://ufldl.stanford.edu/tutorial/>.
- [19] M. Xue, S. Kappagoda y D. K. A. Mordecai, *Energy Disaggregation with Semi-supervised Sparse Coding*, 2020. arXiv: 2004.10529 [eess.SP].
- [20] D. Murray, L. Stankovic y V. Stankovic, «An electrical load measurements dataset of United Kingdom households from a two-year longitudinal study», *Scientific Data*, vol. 4, n.º 1, pág. 160 122, 2017, ISSN: 2052-4463. DOI: 10.1038/sdata.2016.122. dirección: <https://doi.org/10.1038/sdata.2016.122>.

Anexos

Apéndice A

Glosario

Lista de términos y abreviaciones utilizados en el trabajo. Su sentido es facilitar y familiarizar al lector la comprensión de las abreviaciones.

- NILM: Non Intrusive Load Monitoring - Monitorización de Carga No Intrusiva.
- HMM: Hidden Markov Models - Modelos Ocultos de Markov.
- Sparse Coding: Codificación de escasez.
- CSPNet: Cross Stage Partial Network
- PCA: Principal Component Analysis - Análisis de Componentes Principales

Apéndice B

Fórmulas Matemáticas

B.1. Cadenas de Markov y Modelos Ocultos de Markov

Añadir todas las fórmulas relevantes para poder dejar constancia de la teoría matemática

B.2. Modelos Factoriales Ocultos de Markov

B.3. Sparse Coding

Apéndice C

Repositorios

C.1. Código Fuente

aquí irá mi repositorio, con el readme del repositorio

C.2. Repositorios externos

aquí irán los repositorios que he usado. Actualmente solo he usado el SafeMap